

Bank pytań i odpowiedzi

oraz słownik najważniejszych pojęć

Obrona pracy magisterskiej

Synteza piosenki z nut i tekstu z wykorzystaniem agenta AI

Michał Bober: Text Localization, OCR, OMR

Igor Starega: Score IR, interpretacja muzyczna, SVS

Dokument zawiera pytania bezpośrednio dotyczące pracy, pytania ogólne z obszaru uczenia maszynowego, widzenia komputerowego, przetwarzania dokumentów, muzyki symbolicznej i syntezy audio oraz słownik pojęć, których mechanizm należy rozumieć.

Warszawa, 2026

Spis treści

1	Jak odpowiadać na pytania komisji	2
2	Pytania bezpośrednio dotyczące pracy	2
2.1	Cel, architektura i wkład autorów	2
2.2	Tezy i wyniki	3
2.3	Ograniczenia i krytyka	4
3	Pytania ogólne z uczenia maszynowego	5
4	Pytania ogólne: przetwarzanie obrazu i lokalizacja tekstu	8
5	Pytania ogólne: OCR	10
6	Pytania ogólne: OMR i detekcja obiektów	12
7	Pytania ogólne: Score IR i teoria muzyki	16
8	Pytania ogólne: audio i SVS	18
9	Pytania o integrację, testowanie i rozwój systemu	24
10	Słownik najważniejszych pojęć	25
10.1	Uczenie maszynowe i eksperymenty	26
10.2	Widzenie komputerowe, segmentacja i OCR	29
10.3	Detekcja i metryki OMR	32
10.4	Muzyka, reprezentacja i Score IR	33
10.5	Audio i SVS	35
11	Ostatnia lista kontrolna	38

1. Jak odpowiadać na pytania komisji

Odpowiedź powinna mieć prostą strukturę:

1. krótka definicja;
2. zastosowanie w pracy;
3. uzasadnienie wyboru;
4. wynik lub obserwacja;
5. ograniczenie i możliwe ulepszenie.

Jeżeli pytanie jest szerokie, warto najpierw podać odpowiedź w jednym zdaniu, a dopiero później rozwinąć szczegóły. Nie należy przedstawiać ograniczeń jako porażki. Umiejętność ich rozpoznania jest częścią pracy badawczej.

2. Pytania bezpośrednio dotyczące pracy

2.1. Cel, architektura i wkład autorów

Pytanie 1. Jaki był główny cel pracy?

Odpowiedź: Celem było opracowanie i ocena modułowego systemu, który przyjmuje obraz lub PDF partytury wokalne, rozpoznaje tekst i zapis muzyczny, buduje uporządkowaną reprezentację pośrednią, a następnie tworzy dane sterujące syntezą wokalu i akompaniamentu.

Pytanie 2. Jaki problem badawczy rozwiązuje praca?

Odpowiedź: Rozwiązuje problem przejścia od dwuwymiarowego, relacyjnego obrazu partytury do jednowymiarowej osi czasu zawierającej tekst, fonemy, wysokości, czasy trwania i parametry potrzebne do syntezy śpiewu.

Pytanie 3. Jak wygląda pełny pipeline systemu?

Odpowiedź: PDF jest rasteryzowany do obrazów. Następnie lokalizowany jest tekst, cropy przechodzą przez OCR, a równoległy tor OMR wykrywa symbole muzyczne. Wyniki są łączone w Score IR, z którego powstają MusicXML, MIDI, podgląd partytury, CSV/JSON dla SVS oraz audio pianina i wokalu.

Pytanie 4. Dlaczego wybrano architekturę modułową?

Odpowiedź: Poszczególne etapy wymagają innych danych, modeli i metryk. Modułowość pozwala trenować i wymieniać komponenty niezależnie, zapisywać artefakty pośrednie oraz lokalizować źródło błędu, zanim stanie się słyszalne w końcowym audio.

Pytanie 5. Jakie są wady podejścia modułowego?

Odpowiedź: Błędy propagują się pomiędzy etapami, interfejsy mogą tracić informację, a lokalnie najlepszy model nie musi dawać najlepszego wyniku końcowego. System ma również więcej konfiguracji, checkpointów i punktów awarii niż pojedynczy model.

Pytanie 6. Dlaczego nie zastosowano jednego modelu end-to-end?

Odpowiedź: Wymagałby dużego zbioru par obraz partytury–docelowy śpiew oraz wspólnego nauczania analizy dokumentu, semantyki muzycznej, wymowy i generacji audio. Taki zbiór jest trudno dostępny, a wynik byłby znacznie trudniejszy do diagnozowania i kontrolowania.

Pytanie 7. Czy system jest end-to-end?

Odpowiedź: Z punktu widzenia użytkownika tak, ponieważ przechodzi od obrazu do audio. Z punktu widzenia uczenia maszynowego nie jest jednym modelem trenowanym end-to-end, lecz zintegrowanym pipeline’em niezależnych modeli i reguł.

Pytanie 8. Co oznacza „agent AI” w tytule?

Odpowiedź: Nie oznacza autonomicznego LLM. Oznacza zestaw wyspecjalizowanych modułów AI działających jako agenci zadaniowi oraz warstwę orkiestracji, która uruchamia etapy, waliduje wyniki i zapisuje artefakty diagnostyczne.

Pytanie 9. Jaki był wkład Michała Bobera?

Odpowiedź: Lokalizacja tekstu, OCR, OMR, przygotowanie i wykorzystanie DeepScoresV2, konfiguracja Faster R-CNN, kafelkowanie, augmentacje, eksperymenty detekcyjne, obsługa obrazów i PDF-ów oraz integracja toru obrazu z aplikacją.

Pytanie 10. Jaki był wkład Igora Staręgi?

Odpowiedź: Interpretacja partytury, Score IR, rekonstrukcja melodii i rytmu, dopasowanie tekstu do nut, przygotowanie danych wokalnych, rozwój modelu akustycznego i wokodera SVS oraz ewaluacja muzyczna i audio.

Pytanie 11. Co było wspólnym wkładem autorów?

Odpowiedź: Projekt architektury, wybór eksperymentów, przegląd literatury, integracja systemu, testy end-to-end, analiza błędów i opracowanie wniosków.

Pytanie 12. Jaki jest najważniejszy wkład całej pracy?

Odpowiedź: Nie pojedyncza metryka, lecz kompletny i obserwowalny pipeline badawczo-inżynierski od obrazu partytury do jawnej reprezentacji muzyczno-tekstowej i audio, z możliwością diagnostyki każdego etapu.

Pytanie 13. Dlaczego Score IR jest ważnym elementem pracy?

Odpowiedź: Jest kontraktem pomiędzy percepcją obrazu a syntezą. Zachowuje symbole, relacje, źródła, confidence, ostrzeżenia i naprawy. Pozwala odróżnić błąd detekcji od błędu interpretacji muzycznej oraz wygenerować kilka różnych formatów wyjściowych.

Pytanie 14. Dlaczego bezpośredni CSV dla SVS nie wystarcza?

Odpowiedź: CSV zawiera tylko minimalną oś czasu potrzebną syntezie. Nie zachowuje pełnej geometrii, relacji, symboli, ostrzeżeń ani informacji niewykorzystywanych jeszcze przez SVS. Utrudniałby audyt i przyszły rozwój systemu.

Pytanie 15. Jak system umożliwia diagnozowanie błędów?

Odpowiedź: Zapisuje maskę i overlay lokalizacji, wyniki OCR, surowe i filtrowane predykcje OMR, score_ir.json, podgląd SVG, MusicXML, MIDI, odsłuch pianina, CSV dla SVS, tensory diagnostyczne i końcowy waveform.

Pytanie 16. Jak rozpoznać, czy błąd audio powstał w OMR, Score IR czy SVS?

Odpowiedź: Najpierw porównuje się overlay OMR z obrazem, potem Score IR i podgląd SVG, następnie MIDI lub piano WAV, a dopiero później wokal. Jeżeli pianino ma poprawną melodię, a wokal nie, problem leży w danych SVS, modelu akustycznym lub wokoderze.

2.2. Tezy i wyniki

Pytanie 17. Czy teza o obserwowalności systemu została potwierdzona?

Odpowiedź: Częściowo. Artefakty pośrednie rzeczywiście pozwalają przypisywać błędy do etapów, ale obserwowalność oceniono głównie jakościowo, bez formalnej metryki czasu lub skuteczności diagnozy.

Pytanie 18. Jaki był wynik eksperymentu ze stride'em backbone'u?

Odpowiedź: Na Teście bazowym przejście ze stride 16 na 8 zwiększyło mAP z 0,767 do 0,793. Na Teście degradowanym mAP było prawie identyczne, około 0,69, ale stride 8 zwiększył precision i obniżył recall.

Pytanie 19. Jaki był wynik eksperymentu z augmentacjami OMR?

Odpowiedź: Spadek mAP pomiędzy Testem bazowym i degradowanym wynosił 0,272 bez augmentacji, 0,105 dla augmentacji podstawowych i 0,081 dla wariantu heavy. Augmentacje poprawiły odporność na kontrolowane degradacje.

Pytanie 20. Jaki był wynik eksperymentu z kafelkowaniem?

Odpowiedź: Najlepsza była rodzina kafla 768. Konfiguracja 768/256 osiągnęła mAP 0,805 na Teście bazowym, a warianty 768/128 lub 768/256 około 0,721 na Teście degradowanym.

Pytanie 21. Czy większy overlap zawsze poprawiał wyniki?

Odpowiedź: Nie. Zwiększanie overlapu nie dawało monotonicznej poprawy. Rozmiar kafla miał bardziej stabilny wpływ niż overlap, a duży overlap zwiększał koszt i liczbę duplikatów.

Pytanie 22. Jaki był najlepszy wynik lokalizacji tekstu?

Odpowiedź: Attention U-Net osiągnął F1 0,909 i IoU 0,832. U-Net był bardzo blisko: F1 0,906 i IoU 0,828.

Pytanie 23. Jaki był najlepszy wynik własnego OCR?

Odpowiedź: ResNet-CRNN hidden512 osiągnął CER 0,1318 i exact match accuracy 0,5366 na 16842 próbkach.

Pytanie 24. Jaki był finalny wynik SVS?

Odpowiedź: Na dziesięciu próbkach oracle wariant clean ze score F_0 osiągnął średni MAE 8,87 centa, P95 40,38 centa i 2,59% ramek z błędem większym niż półton.

Pytanie 25. Co pokazała ablacja źródła F_0 ?

Odpowiedź: Score F_0 dało 8,87 centa MAE, blend 15,35, a predicted 22,76. Jawna melodia z partytury była więc najbezpieczniejszym źródłem wysokości dla kontrolowanej syntezy.

Pytanie 26. Dlaczego wariant humanized miał gorszy MAE?

Odpowiedź: Celowo dodawał vibrato, podciągnięcie i powolny drift, więc odchyłał wysokość od idealnej linii partytury. Jego MAE wzrosło do 9,69 centa, ale nie nastąpił duży wzrost poważnych błędów wysokości.

2.3. Ograniczenia i krytyka

Pytanie 27. Jakie jest najważniejsze ograniczenie metodologiczne OMR?

Odpowiedź: Zbiór `deepscores_test.json` był wykorzystywany do monitorowania mAP, wyboru checkpointu i raportowania wyniku. Brakowało oddzielnego zbioru walidacyjnego i nietykanego testowego.

Pytanie 28. Dlaczego pojedynczy seed jest problemem?

Odpowiedź: Nie pozwala oszacować wariancji wynikającej z inicjalizacji, kolejności danych i losowych augmentacji. Małe różnice pomiędzy modelami mogą być przypadkowe.

Pytanie 29. Dlaczego eksperyment z kafelkami nie był w pełni kontrolowany?

Odpowiedź: Różne rozmiary i overlap generowały różną liczbę kafla. Przy tej samej liczbie epok modele wykonywały różną liczbę aktualizacji optymalizatora.

Pytanie 30. Czy Test degradowany potwierdza działanie na zdjęciach telefonu?

Odpowiedź: Nie. Potwierdza odporność na konkretny zestaw syntetycznych transformacji. Prawdziwe zdjęcia mogą zawierać inne cienie, perspektywę, zagięcia, odbicia, rozmycie i różne fonty muzyczne.

Pytanie 31. Jakie jest główne ograniczenie lokalizacji tekstu i OCR?

Odpowiedź: Dane treningowe pochodziły głównie z ogólnych dokumentów, a nie z partytur. Powoduje to przesunięcie domenowe i ryzyko mylenia cienkich symboli muzycznych z tekstem.

Pytanie 32. Jakie jest główne ograniczenie SVS?

Odpowiedź: Ewaluacja wykorzystuje mały, dziesięcioelementowy golden set i przede wszystkim metryki wysokości. Brakuje szerokiego, zaślepionego testu percepcyjnego naturalności, zrozumiałości, barwy i frazowania.

Pytanie 33. Czy wynik 8,87 centa oznacza naturalny śpiew?

Odpowiedź: Nie. Oznacza dobrą zgodność F_0 waveformu z melodią. Nie mierzy bezpośrednio naturalności, barwy, artykulacji, zrozumiałości ani podobieństwa do prawdziwego wykonawcy.

Pytanie 34. Czy system osiąga jakość użytkową?

Odpowiedź: Jest działającym prototypem badawczo-inżynierskim, ale nie produktem porównywalnym z komercyjnymi narzędziami. Potrzebuje szerszych danych, odporności domenowej, testów użytkowników, stabilniejszego SVS i narzędzi ręcznej korekty.

Pytanie 35. Czy zakres pracy był zbyt szeroki?

Odpowiedź: Szerokość była potrzebna do zbadania pełnego przejścia od obrazu do audio, ale jej ceną jest nierówna głębokość modułów. OMR jest udokumentowane eksperymentalnie mocniej niż SVS.

Pytanie 36. Co autorzy zrobiliby inaczej, mając więcej czasu?

Odpowiedź: Przygotowaliby prawdziwy zbiór partytur wokalnych, oddzielny validation i test, wiele seedów, metryki sylabizacji OCR, porównanie z silnymi baseline'ami, rotated detection oraz pełny test percepcyjny SVS.

3. Pytania ogólne z uczenia maszynowego

Pytanie 37. Czym różni się uczenie nadzorowane od nienadzorowanego?

Odpowiedź: W uczeniu nadzorowanym próbki mają etykiety i model uczy się mapowania wejścia na cel. W nienadzorowanym model szuka struktury bez jawnych etykiet, np. klastrów lub reprezentacji. Modele w pracy były trenowane głównie nadzorowanie.

Pytanie 38. Czym różni się klasyfikacja, regresja, detekcja i segmentacja?

Odpowiedź: Klasyfikacja przypisuje klasę całej próbce, regresja przewiduje wartości ciągłe, detekcja przewidywa klasy i położenia wielu obiektów, a segmentacja przypisuje etykietę pikselom.

Pytanie 39. Czym jest funkcja straty?

Odpowiedź: To różniczkowalna miara błędu używana do obliczenia gradientu i aktualizacji wag. Nie musi być identyczna z metryką raportowaną użytkownikowi.

Pytanie 40. Dlaczego strata walidacyjna i końcowa metryka mogą dawać inny ranking modeli?

Odpowiedź: Strata jest lokalnym celem optymalizacji, a metryka może obejmować progi, ranking confidence, NMS, klasy, całe strony lub percepcję. Dobra optymalizacja surrogate loss nie gwarantuje najlepszego wyniku zadaniowego.

Pytanie 41. Co to jest gradient descent?

Odpowiedź: Metoda aktualizacji parametrów w kierunku przeciwnym do gradientu funkcji straty. Learning rate określa wielkość kroku.

Pytanie 42. Czym różni się SGD od Adam?

Odpowiedź: SGD korzysta bezpośrednio z gradientu, często z momentum. Adam adaptuje krok dla każdego parametru na podstawie estymat pierwszego i drugiego momentu gradientu, zwykle szybciej osiągając dobre rozwiązanie.

Pytanie 43. Czym AdamW różni się od Adam z naiwnym L2?

Odpowiedź: AdamW rozdziela weight decay od adaptacyjnej aktualizacji gradientu. Dzięki temu regularyzacja ma bardziej przewidywalne działanie.

Pytanie 44. Co to jest learning rate?

Odpowiedź: To współczynnik określający wielkość aktualizacji wag. Zbyt wysoki powoduje niestabilność, a zbyt niski bardzo wolne uczenie lub utknięcie.

Pytanie 45. Po co stosuje się scheduler learning rate?

Odpowiedź: Pozwala zmniejszać krok, gdy trening przestaje się poprawiać. W OMR użyto ReduceLROnPlateau, który reaguje na brak poprawy monitorowanej metryki.

Pytanie 46. Co to jest epoch, batch i optimizer step?

Odpowiedź: Epoch to przejście przez zbiór treningowy, batch to grupa próbek przetwarzanych razem, a optimizer step to pojedyncza aktualizacja wag. Ta sama liczba epok nie gwarantuje tej samej liczby kroków, jeśli zbiory mają różną wielkość.

Pytanie 47. Co to jest batch size i jak wpływa na trening?

Odpowiedź: Określa liczbę próbek używanych do jednego gradientu. Większy batch daje stabilniejszy gradient, ale wymaga więcej pamięci. W OMR batch 1 wynikał z dużych obrazów i wielu obiektów.

Pytanie 48. Co to jest overfitting?

Odpowiedź: Model uczy się szczegółów danych treningowych, które nie generalizują. Objawia się poprawą treningu przy pogarszaniu lub stagnacji walidacji.

Pytanie 49. Jak ograniczać overfitting?

Odpowiedź: Większa liczba danych, augmentacja, weight decay, dropout, early stopping, prostszy model, transfer learning i poprawny podział danych.

Pytanie 50. Co to jest underfitting?

Odpowiedź: Model jest zbyt prosty, za krótko trenowany lub źle optymalizowany i nie osiąga dobrego wyniku nawet na danych treningowych.

Pytanie 51. Co to jest early stopping?

Odpowiedź: Zatrzymanie treningu po określonej liczbie epok bez wystarczającej poprawy walidacji. Ogranicza przeuczenie i koszt, ale zależy od jakości zbioru walidacyjnego.

Pytanie 52. Co to jest dropout?

Odpowiedź: Podczas treningu losowo zeruje część aktywacji. Zmusza model do rozproszenia informacji i działa jak regularyzacja. W inferencji dropout jest wyłączony.

Pytanie 53. Co to jest weight decay?

Odpowiedź: Kara za duże wartości wag, która ogranicza złożoność rozwiązania. W AdamW jest stosowana jako bezpośrednie zmniejszanie parametrów.

Pytanie 54. Co to jest gradient clipping?

Odpowiedź: Ograniczenie normy lub wartości gradientu. Chroni przed eksplozją gradientów, szczególnie w modelach sekwencyjnych i niestabilnych treningach.

Pytanie 55. Co to jest mixed precision?

Odpowiedź: Używanie niższej precyzji, np. FP16, tam gdzie jest bezpieczna, oraz FP32 dla wrażliwych operacji. Zmniejsza pamięć i przyspiesza trening na GPU.

Pytanie 56. Czym jest seed losowy?

Odpowiedź: Wartość inicjalizująca generatory liczb losowych. Pomaga odtwarzać eksperyment, ale jeden seed nie opisuje zmienności metody.

Pytanie 57. Co to jest hiperparametr?

Odpowiedź: Parametr ustalany poza procesem uczenia, np. learning rate, batch size, liczba warstw, próg confidence, rozmiar kafla lub siła augmentacji.

Pytanie 58. Czym różni się parametr modelu od hiperparametru?

Odpowiedź: Parametry, np. wagi sieci, są uczone przez optymalizację. Hiperparametry są wybierane przez badacza lub zewnętrzny algorytm strojenia.

Pytanie 59. Co to jest transfer learning?

Odpowiedź: Wykorzystanie modelu lub encodera wytrenowanego wcześniej na innym zadaniu. Może przyspieszyć uczenie i poprawić generalizację, ale domena źródłowa może być niedopasowana.

Pytanie 60. Co to jest fine-tuning?

Odpowiedź: Dalszy trening wstępnie wyuczonego modelu na nowym zbiorze lub rozkładzie danych, zwykle z mniejszym learning rate.

Pytanie 61. Co to jest ablation study?

Odpowiedź: Kontrolowane usunięcie albo zmiana składnika systemu w celu określenia jego wpływu. W pracy przykładem jest porównanie źródła F_0 : score, blend i predicted.

Pytanie 62. Co to jest baseline?

Odpowiedź: Punkt odniesienia, który powinien być poprawnie zaimplementowany i oceniany na tych samych danych oraz metrykach. Pozwala stwierdzić, czy złożone rozwiązanie rzeczywiście coś poprawia.

Pytanie 63. Co to jest data leakage?

Odpowiedź: Przepływ informacji z walidacji lub testu do treningu albo wyboru modelu. Powoduje optymistyczny wynik, który może nie powtórzyć się na nowych danych.

Pytanie 64. Co to jest domain shift?

Odpowiedź: Różnica rozkładu pomiędzy danymi treningowymi i docelowymi, np. czyste syntetyczne partytury kontra zdjęcia z telefonu.

Pytanie 65. Co to jest class imbalance?

Odpowiedź: Duża różnica liczby przykładów klas. Model może ignorować rzadkie klasy lub faworyzować tło. Rozwiązania obejmują ważenie strat, sampling, focal loss i augmentację.

Pytanie 66. Dlaczego dokładność nie zawsze jest dobrą metryką?

Odpowiedź: Przy niezbalansowanych klasach można osiągnąć wysoką accuracy, ignorując klasę rzadką. W segmentacji tekstu prawie wszystkie piksele są tłem.

Pytanie 67. Co oznacza istotność statystyczna?

Odpowiedź: Ocena, czy obserwowana różnica jest mało prawdopodobna przy założeniu braku realnego efektu. W uczeniu maszynowym należy dodatkowo raportować rozmiar efektu, wariancję i praktyczne znaczenie różnicy.

Pytanie 68. Dlaczego warto raportować średnią i odchylenie po wielu seedach?

Odpowiedź: Pokazują typowy wynik oraz stabilność metody. Pojedynczy najlepszy run może być szczęśliwym przypadkiem.

4. Pytania ogólne: przetwarzanie obrazu i lokalizacja tekstu**Pytanie 69. Co to jest obraz rastrowy?**

Odpowiedź: Macierz pikseli. Każdy piksel przechowuje wartość jasności lub kanały barw. Rozdzielczość określa liczbę pikseli, a nie fizyczny rozmiar dokumentu.

Pytanie 70. Co to jest binaryzacja obrazu?

Odpowiedź: Przekształcenie obrazu do dwóch klas, zwykle atrament i tło. Może być globalna lub adaptacyjna. Jest użyteczna w morfologii i analizie pięciolinii.

Pytanie 71. Czym różni się progowanie globalne od adaptacyjnego?

Odpowiedź: Globalne używa jednego progu dla całego obrazu. Adaptacyjne wyznacza próg lokalnie, więc lepiej radzi sobie z nierównym oświetleniem, ale może wzmacniać lokalny szum.

Pytanie 72. Co to jest erozja?

Odpowiedź: Operacja morfologiczna zmniejszająca jasny obszar maski. Może usuwać drobny szum i rozdzielać połączone elementy, ale może zniszczyć cienkie znaki.

Pytanie 73. Co to jest dylatacja?

Odpowiedź: Powiększa jasny obszar maski. Łączy bliskie fragmenty i wzmacnia cienkie elementy, ale może scalać osobne obiekty.

Pytanie 74. Czym są opening i closing?

Odpowiedź: Opening to erozja, a potem dylatacja: usuwa małe jasne elementy. Closing to dylatacja, a potem erozja: zamyka przerwy i łączy bliskie fragmenty.

Pytanie 75. Co to jest kontur?

Odpowiedź: Granica spójnego obszaru maski. Analiza konturów pozwala obliczyć pole i bounding box regionu.

Pytanie 76. Co to jest connected component?

Odpowiedź: Maksymalny zbiór sąsiadujących pikseli tej samej klasy. Jest alternatywnym sposobem wyznaczania regionów po segmentacji.

Pytanie 77. Czym różni się segmentacja semantyczna od detekcji?

Odpowiedź: Segmentacja przewiduje klasę każdego piksela, a detekcja zwraca prostokąty i klasy obiektów. Segmentacja daje dokładniejszy kształt, detekcja prostsze instancje.

Pytanie 78. Czym różni się segmentacja semantyczna od instancyjnej?

Odpowiedź: Semantyczna łączy wszystkie obiekty tej samej klasy w jedną maskę klasową. Instancyjna różni osobne obiekty.

Pytanie 79. Jak działa konwolucja?

Odpowiedź: Mały filtr przesuwany po obrazie i oblicza ważoną sumę lokalnego sąsiedztwa. Uczzone filtry wykrywają krawędzie, tekstury i bardziej złożone wzorce.

Pytanie 80. Co to jest kernel konwolucyjny?

Odpowiedź: Macierz uczonych wag stosowana lokalnie do obrazu lub mapy cech. Rozmiar kernela wpływa na lokalny kontekst i koszt.

Pytanie 81. Co to jest padding?

Odpowiedź: Dodanie wartości wokół obrazu przed konwolucją. Pozwala kontrolować rozmiar wyjścia i zachować informacje przy krawędziach.

Pytanie 82. Co to jest stride konwolucji?

Odpowiedź: Krok przesuwania filtra. Stride większy od 1 zmniejsza rozdzielczość mapy cech.

Pytanie 83. Co to jest pooling?

Odpowiedź: Operacja zmniejszająca rozdzielczość, np. max pooling wybiera maksimum w oknie. Zwiększa pole recepcyjne, ale traci szczegóły przestrzenne.

Pytanie 84. Co to jest pole recepcyjne?

Odpowiedź: Obszar obrazu wejściowego, który może wpływać na daną aktywację. Głębsze warstwy mają większe pole recepcyjne i widzą szerszy kontekst.

Pytanie 85. Jak działa U-Net?

Odpowiedź: Encoder kompresuje obraz, decoder odtwarza rozdzielczość, a skip connections przekazują drobne szczegóły z odpowiadających poziomów encodera.

Pytanie 86. Po co są skip connections w U-Net?

Odpowiedź: Downsampling usuwa dokładną informację o położeniu. Skip connections dostarczają decoderowi cechy wysokiej rozdzielczości potrzebne do odtworzenia granic i cienkich liter.

Pytanie 87. Jak działa Attention U-Net?

Odpowiedź: Attention gates obliczają mapę wag dla cech przekazywanych skip connection. Wzmacniają obszary przydatne decoderowi i tłumią część tła.

Pytanie 88. Czym jest U-Net++?

Odpowiedź: Wariant U-Net z zagnieżdżonymi i gęstymi połączeniami pomiędzy encoderem i decoderem, mający zmniejszyć różnicę semantyczną cech.

Pytanie 89. Jak działa DeepLabV3+?

Odpowiedź: Wykorzystuje atrous convolutions do zbierania kontekstu na kilku skalach oraz decoder poprawiający granice segmentacji.

Pytanie 90. Co to jest atrous/dilated convolution?

Odpowiedź: Konwolucja z odstępami pomiędzy elementami kernela. Zwiększa pole recepcyjne bez proporcjonalnego zwiększenia liczby parametrów i bez dodatkowego downsamplingu.

Pytanie 91. Co to jest FPN?

Odpowiedź: Feature Pyramid Network łączy głębokie cechy semantyczne z płytszymi cechami wysokiej rozdzielczości, tworząc reprezentacje dla kilku skal obiektów.

Pytanie 92. Co to jest BatchNorm?

Odpowiedź: Normalizuje aktywacje przy użyciu statystyk batcha, a następnie stosuje uczoną skalę i przesunięcie. Przy bardzo małym batchu statystyki mogą być niestabilne.

Pytanie 93. Co to jest GroupNorm?

Odpowiedź: Dzieli kanały pojedynczej próbki na grupy i normalizuje każdą grupę. Nie zależy od liczby obrazów w batchu, dlatego jest użyteczna przy batch size 1.

Pytanie 94. Czym jest funkcja ReLU?

Odpowiedź: $\text{ReLU}(x) = \max(0, x)$. Wprowadza nieliniowość i jest tania obliczeniowo, ale neurony mogą pozostać nieaktywne dla stale ujemnych wejść.

Pytanie 95. Czym jest SiLU?

Odpowiedź: $\text{SiLU}(x) = x\sigma(x)$. Jest gładką aktywacją, która zachowuje niewielkie wartości ujemne i była użyta we własnym backbone OMR.

Pytanie 96. Dlaczego BCE i Dice Loss można łączyć?

Odpowiedź: BCE daje stabilny błąd pikselowy, a Dice bezpośrednio optymalizuje nakładanie się masek i ogranicza wpływ dominującego tła.

Pytanie 97. Co robi parametr pos_weight w BCE?

Odpowiedź: Zwiększa koszt błędów klasy pozytywnej. W lokalizacji tekstu pomaga, ponieważ pikseli tekstu jest znacznie mniej niż tła.

Pytanie 98. Jaka jest różnica między IoU i Dice?

Odpowiedź: Obie mierzą nakładanie. IoU dzieli przecięcie przez sumę zbiorów, a Dice podwójne przecięcie przez sumę pól. Dice jest monotonicznie związany z IoU.

Pytanie 99. Jak dobiera się próg maski?

Odpowiedź: Na zbiorze walidacyjnym, analizując kompromis precision–recall i wpływ na dalszy pipeline. Zbyt niski próg generuje false positives, zbyt wysoki pomija tekst.

5. Pytania ogólne: OCR

Pytanie 100. Czym jest OCR?

Odpowiedź: Optical Character Recognition to przekształcanie obrazu tekstu do sekwencji znaków. Może obejmować detekcję tekstu, korekcję regionów i rozpoznawanie.

Pytanie 101. Jak działa CRNN?

Odpowiedź: CNN tworzy mapę cech obrazu, wymiar poziomy jest traktowany jako sekwencja, BiLSTM modeluje kontekst, a głowica CTC przewiduje znaki bez jawnego dopasowania ich do pikseli.

Pytanie 102. Dlaczego wysokość obrazu jest kompresowana, a szerokość zachowywana?

Odpowiedź: Tekst jest czytany od lewej do prawej. Wysokość zawiera kształt znaków, który można skompresować do cech, natomiast szerokość reprezentuje kolejność znaków.

Pytanie 103. Co to jest RNN?

Odpowiedź: Sieć przetwarzająca sekwencję z ukrytym stanem przenoszącym informację pomiędzy krokami. Klasyczne RNN mają problem z długimi zależnościami i zanikaniem gradientu.

Pytanie 104. Jak działa LSTM?

Odpowiedź: Używa stanu komórki oraz bramek wejścia, zapominania i wyjścia, aby kontrolować przepływ informacji. Ułatwia modelowanie dłuższych zależności.

Pytanie 105. Co oznacza BiLSTM?

Odpowiedź: Dwa LSTM przetwarzają sekwencję w przeciwnych kierunkach. Ich reprezentacje są łączone, dzięki czemu znak korzysta z kontekstu po obu stronach.

Pytanie 106. Co to jest residual block w ResNet?

Odpowiedź: Blok uczący poprawkę $F(x)$, którą dodaje się do wejścia. Skrót pomaga propagacji gradientu i uczeniu głębszych modeli.

Pytanie 107. Jak działa CTC?

Odpowiedź: Model przewiduje dłuższą sekwencję etykiet i blanków. CTC sumuje prawdopodobieństwa monotonicznych ścieżek, które po usunięciu blanków i scaleniu powtórzeń dają tekst docelowy.

Pytanie 108. Po co CTC używa blank tokenu?

Odpowiedź: Oznacza brak znaku w danym kroku i pozwala rozdzielać powtarzające się litery, które inaczej zostałyby scalone.

Pytanie 109. Jakie założenie ma CTC?

Odpowiedź: Kolejność etykiet jest monotoniczna względem wejścia. CTC nie modeluje swobodnych przestawień znaków.

Pytanie 110. Czym różni się greedy decoding od beam search?

Odpowiedź: Greedy wybiera najlepszą klasę w każdym kroku. Beam search utrzymuje kilka hipotez pełnej sekwencji i może łączyć wynik z modelem językowym.

Pytanie 111. Dlaczego beam search może być lepszy?

Odpowiedź: Najbardziej prawdopodobna lokalna decyzja nie musi tworzyć najbardziej prawdopodobnego pełnego napisu. Beam search uwzględnia alternatywne ścieżki.

Pytanie 112. Co to jest charset?

Odpowiedź: Zbiór znaków rozpoznawanych przez model. Liczba klas CTC to liczba znaków plus blank. Zmiana charsetu bez zgodnego checkpointu powoduje niezgodność głowicy modelu.

Pytanie 113. Dlaczego myślnik jest ważny w OCR partytury?

Odpowiedź: Może oznaczać podział słowa na sylaby przypisane kolejnym nutom. Jego utrata zmienia synchronizację tekstu i melodii.

Pytanie 114. Co to jest edit distance?

Odpowiedź: Minimalna liczba podstawień, usunięć i wstawień potrzebnych do zmiany jednego napisu w drugi. Jest podstawą CER i WER.

Pytanie 115. Jak oblicza się CER?

Odpowiedź:

$$\text{CER} = \frac{S + D + I}{N},$$

gdzie S , D , I to podstawienia, usunięcia i wstawienia, a N długość referencji.

Pytanie 116. Czym różni się CER od WER?

Odpowiedź: CER liczy operacje na znakach, a WER na słowach. CER jest dokładniejszy dla krótkich cropów i sylab, WER lepiej opisuje pełne wypowiedzi.

Pytanie 117. Co to jest exact match accuracy?

Odpowiedź: Odsetek próbek, dla których cały napis jest identyczny z referencją. Jeden błędny znak powoduje błąd całej próbki.

Pytanie 118. Dlaczego CER może być niski, a exact match znacznie niższy?

Odpowiedź: Wiele napisów może mieć tylko jeden drobny błąd. CER uzna go za małą różnicę, ale exact match odrzuci całą próbkę.

Pytanie 119. Czy CER może przekroczyć 100%?

Odpowiedź: Tak, jeżeli model wygeneruje dużo dodatkowych znaków i liczba wstawień przekroczy długość referencji.

Pytanie 120. Jak działa Transformer w OCR?

Odpowiedź: Self-attention modeluje zależności pomiędzy wszystkimi pozycjami cech obrazu. Kodowanie pozycyjne informuje o kolejności, a głowica może być CTC lub autoregresyjna.

Pytanie 121. Dlaczego Transformer potrzebuje kodowania pozycyjnego?

Odpowiedź: Self-attention bez dodatkowej informacji jest niezmienniczy na permutację pozycji i nie zna naturalnej kolejności sekwencji.

Pytanie 122. Jak działa TrOCR?

Odpowiedź: Encoder obrazu tworzy reprezentację wizualną, a autoregresyjny Transformer decoder generuje tekst token po tokenie, warunkując kolejny token na poprzednich.

Pytanie 123. Czym TrOCR różni się od modelu Transformer-CTC?

Odpowiedź: TrOCR używa autoregresyjnego dekodera i jawnie modeluje zależności między wygenerowanymi tokenami. Transformer-CTC przewiduje etykiety równoległe nad osią cech i używa redukcji CTC.

Pytanie 124. Jak poprawić OCR tekstu wokalnego?

Odpowiedź: Fine-tuning na partyturach, lepsze cropy, zachowanie pełnych wierszy, beam search, model językowy, słownik i metryki oceniające sylabizację oraz zgodność z liczbą nut.

6. Pytania ogólne: OMR i detekcja obiektów

Pytanie 125. Czym OMR różni się od OCR?

Odpowiedź: OMR odtwarza strukturę muzyczną, w której znaczenie symbolu zależy od położenia i relacji. OCR zwykłe odczytuje liniową sekwencję znaków.

Pytanie 126. Dlaczego samo wykrycie notehead nie daje jeszcze nuty?

Odpowiedź: Do ustalenia wysokości potrzebne są pięciolinia, klucz i znaki chromatyczne, a do czasu trwania stem, beam, flag, kropka i kontekst rytmiczny.

Pytanie 127. Czym jest DeepScoresV2?

Odpowiedź: Duży syntetyczny zbiór drukowanych partytur do detekcji obiektów muzycznych, zawierający 136 klas, axis-aligned i oriented bounding boxes oraz bardzo wiele małych obiektów.

Pytanie 128. Jakie są zalety syntetycznych danych OMR?

Odpowiedź: Duża skala, precyzyjne i tanie adnotacje, kontrola klas i możliwość automatycznego generowania wielu wariantów.

Pytanie 129. Jakie są wady syntetycznych danych?

Odpowiedź: Brak części cech rzeczywistych zdjęć i skanów, inny rozkład fontów, szumu, układów stron i artefaktów. Model może nauczyć się cech generatora.

Pytanie 130. Czym różni się wariant dense od complete?

Odpowiedź: Dense koncentruje się na gęsto anotowanych symbolach i był używany w głównych eksperymentach. Complete obejmuje szerszy wariant danych. Dokładne porównanie wymaga zachowania tego samego protokołu i budżetu.

Pytanie 131. Jak działa Faster R-CNN?

Odpowiedź: Backbone tworzy mapę cech. RPN generuje proposals. RoIAlign pobiera cechy każdego regionu, a drugi etap klasyfikuje obiekt i doprecyzowuje bounding box.

Pytanie 132. Co to jest backbone detektora?

Odpowiedź: Sieć przekształcająca obraz w mapy cech. Jej rozdzielczość, pole recepcyjne i jakość cech wpływają na zdolność wykrywania obiektów.

Pytanie 133. Co to jest RPN?

Odpowiedź: Region Proposal Network przewiduje dla anchors prawdopodobieństwo obiektu i poprawkę boxa, tworząc listę regionów kandydackich dla drugiego etapu.

Pytanie 134. Co to jest anchor?

Odpowiedź: Wstępny prostokąt o określonym rozmiarze i proporcji umieszczany w pozycji mapy cech. Model przewiduje, czy odpowiada obiektowi oraz jak go przesunąć i przeskalować.

Pytanie 135. Dlaczego w OMR potrzebne są mikro-kotwice?

Odpowiedź: Wiele symboli ma tylko kilka pikseli po przeskalowaniu. Standardowe anchors z detekcji obrazów naturalnych byłyby zbyt duże.

Pytanie 136. Dlaczego potrzebne są ekstremalne aspect ratios?

Odpowiedź: Stem i barline są cienkie i pionowe, beam oraz staff są długie i poziome, a zwykłe proporcje 0,5–2 nie opisują dobrze ich geometrii.

Pytanie 137. Jak anchors są przypisywane do ground truth podczas treningu?

Odpowiedź: Na podstawie IoU. Kotwice o wysokim IoU stają się pozytywne, o niskim negatywne, a część pośrednich może być ignorowana.

Pytanie 138. Co to jest objectness?

Odpowiedź: Prawdopodobieństwo, że region zawiera dowolny obiekt pierwszoplanowy, niezależnie od jego konkretnej klasy.

Pytanie 139. Co to jest bounding-box regression?

Odpowiedź: Przewidywanie korekty położenia i rozmiaru wstępnego boxa, zwykle jako przesunięcia środka i logarytmiczne zmiany szerokości oraz wysokości.

Pytanie 140. Co to jest RoIAlign?

Odpowiedź: Operacja pobierająca mapę cech o stałym rozmiarze z regionu o dowolnym rozmiarze, używając interpolacji bez brutalnego zaokrąglania współrzędnych.

Pytanie 141. Czym RoIAlign różni się od RoIPool?

Odpowiedź: RoIPool kwantyzuje granice regionu, co powoduje błędy położenia. RoIAlign zachowuje współrzędne zmiennoprzecinkowe i interpoluje cechy.

Pytanie 142. Co to jest NMS?

Odpowiedź: Non-Maximum Suppression usuwa nachodzące detekcje tej samej klasy, pozostawiając najwyżej ocenione boxy.

Pytanie 143. Jak próg NMS wpływa na wynik?

Odpowiedź: Niski próg agresywnie usuwa boxy i może skasować bliskie prawdziwe obiekty. Wysoki próg pozostawia więcej duplikatów.

Pytanie 144. Co to jest confidence score?

Odpowiedź: Ocena pewności predykcji. Nie musi być dobrze skalibrowanym prawdopodobieństwem. Próg confidence steruje kompromisem precision–recall.

Pytanie 145. Co to jest IoU?

Odpowiedź:

$$\text{IoU} = \frac{\text{pole przecięcia}}{\text{pole sumy}}.$$

Mierzy nakładanie przewidzianego i referencyjnego boxa.

Pytanie 146. Dlaczego IoU jest surowe dla małych obiektów?

Odpowiedź: Przesunięcie o kilka pikseli jest dużą częścią małego boxa i może gwałtownie obniżyć IoU.

Pytanie 147. Co to jest precision w detekcji?

Odpowiedź: Odsetek predykcji uznanych za prawdziwe: $TP/(TP + FP)$.

Pytanie 148. Co to jest recall w detekcji?

Odpowiedź: Odsetek obiektów referencyjnych, które wykryto: $TP/(TP + FN)$.

Pytanie 149. Co to jest F1?

Odpowiedź: Średnia harmoniczna precision i recall. Jest wysoka tylko wtedy, gdy oba wyniki są wysokie.

Pytanie 150. Co to jest krzywa precision–recall?

Odpowiedź: Wykres precision względem recall przy zmianie progu confidence. Pokazuje kompromis pomiędzy fałszywymi predykcjami i pominięciami.

Pytanie 151. Co to jest AP?

Odpowiedź: Average Precision to pole pod krzywą precision–recall dla jednej klasy i określonego progu IoU.

Pytanie 152. Czym różni się AP50 od AP75?

Odpowiedź: AP50 wymaga IoU co najmniej 0,5, a AP75 co najmniej 0,75. AP75 silniej ocenia dokładność lokalizacji.

Pytanie 153. Co oznacza mAP w tej pracy?

Odpowiedź: Średnią AP po klasach i progach IoU od 0,50 do 0,95 ze skokiem 0,05.

Pytanie 154. Dlaczego mAP może nie odpowiadać jakości muzycznej?

Odpowiedź: Traktuje klasy według protokołu detekcyjnego, ale błędy różnych symboli mają różny wpływ. Pominięty clef lub notehead może być ważniejszy niż błąd nieużywanej artykulacji.

Pytanie 155. Co to jest macro-average?

Odpowiedź: Średnia, w której każda klasa ma podobną wagę niezależnie od liczby instancji. Podkreśla wyniki klas rzadkich.

Pytanie 156. Co to jest micro-average?

Odpowiedź: Agregacja wszystkich instancji przed liczeniem metryki. Jest zdominowana przez klasy częste.

Pytanie 157. Co to jest support klasy?

Odpowiedź: Liczba referencyjnych instancji klasy. Wynik klasy z supportem 1 jest znacznie mniej stabilny niż wynik klasy z tysiącami obiektów.

Pytanie 158. Co to jest output stride backbone'u?

Odpowiedź: Stosunek przesunięcia na obrazie do przesunięcia o jedną komórkę mapy cech. Stride 8 oznacza mapę dwukrotnie gęstsza w każdym wymiarze niż stride 16.

Pytanie 159. Dlaczego mniejszy stride pomaga małym obiektom?

Odpowiedź: Zachowuje więcej szczegółów przestrzennych i daje więcej pozycji cech dla małego symbolu. Kosztem jest większa pamięć i liczba obliczeń.

Pytanie 160. Dlaczego mniejszy stride może obniżyć recall po degradacji?

Odpowiedź: Wyższa rozdzielczość może być bardziej wrażliwa na lokalny szum, a zmiana cech i confidence może prowadzić do bardziej konserwatywnych predykcji. Efekt nie zależy wyłącznie od detalu.

Pytanie 161. Dlaczego stosuje się kafelkowanie stron?

Odpowiedź: Pozwala zachować wysoką rozdzielczość symboli bez przetwarzania całej ogromnej strony naraz.

Pytanie 162. Co się dzieje z symbolem przeciętym granicą kafla?

Odpowiedź: Może być częściowo widoczny lub wygenerować słabą predykcję. Overlap daje szansę, że w sąsiednim kaflu będzie widoczny w całości.

Pytanie 163. Dlaczego za duży kafel może pogorszyć wynik?

Odpowiedź: Po dopasowaniu do rozmiaru wejściowego symbole zajmują mniej pikseli, więc model traci szczegóły. Zysk kontekstu nie zawsze to rekompensuje.

Pytanie 164. Dlaczego za mały kafel może pogorszyć wynik?

Odpowiedź: Traci szerszy kontekst i częściej przecina długie symbole lub całe systemy.

Pytanie 165. Co to jest oriented bounding box?

Odpowiedź: Ramka lub wielokąt dopasowany do orientacji obiektu, a nie osi obrazu. Lepszy dla ukośnych, cienkich i wydłużonych symboli.

Pytanie 166. Dlaczego oriented box jest przydatny dla slur i beam?

Odpowiedź: Axis-aligned box zawiera dużo tła i sąsiednich symboli. Zorientowany wielokąt lepiej opisuje rzeczywistą geometrię.

Pytanie 167. Co to jest Smooth L1 Loss?

Odpowiedź: Strata zachowująca się kwadratowo dla małych błędów i liniowo dla dużych. Jest mniej wrażliwa na outliery niż MSE i często używana w regresji boxów.

Pytanie 168. Jak działają augmentacje geometryczne?

Odpowiedź: Zmieniają położenie lub kształt obrazu, np. przez skalę, obrót i perspektywę. Te same transformacje muszą zostać zastosowane do adnotacji.

Pytanie 169. Jak działają augmentacje fotometryczne?

Odpowiedź: Zmieniają wygląd bez zmiany geometrii, np. jasność, kontrast, gamma, szum, blur, JPEG i nierówne oświetlenie.

Pytanie 170. Co symulują ink spread i ink thinning?

Odpowiedź: Rozlewanie i zanikanie atramentu, grubość druku oraz artefakty skanu. Są realizowane operacjami podobnymi do filtrów minimum i maksimum.

Pytanie 171. Dlaczego augmentacje mogą pogorszyć clean accuracy?

Odpowiedź: Model przeznaczony na szerszy rozkład i widzi trudniejsze próbki. Zyskuje odporność kosztem idealnego dopasowania do czystej domeny.

Pytanie 172. Czym Faster R-CNN różni się od YOLO?

Odpowiedź: Faster R-CNN jest dwustopniowy i zwykle dokładniejszy kosztem szybkości. YOLO jest jedno-stopniowy, szybki i prostszy w inferencji.

Pytanie 173. Czym jest RetinaNet?

Odpowiedź: Jednostopniowy detektor wykorzystujący focal loss do ograniczenia dominacji łatwych negatywnych przykładów.

Pytanie 174. Czym jest FCOS?

Odpowiedź: Anchor-free detector, który przewiduje klasę i odległości do granic boxa dla pozycji mapy cech.

Pytanie 175. Czym jest DETR?

Odpowiedź: Detektor oparty na Transformerze i set prediction. Używa stałego zbioru zapytań obiektowych i dopasowania bipartite, ograniczając potrzebę anchors i NMS.

Pytanie 176. Dlaczego klasyczny DETR może mieć problem z małymi obiektami?

Odpowiedź: Ma wolną zbieżność i ograniczoną rozdzielczość attention nad mapą cech. Deformable DETR próbkuje wieloskalowe punkty i jest lepszym wariantem dla małych obiektów.

7. Pytania ogólne: Score IR i teoria muzyki

Pytanie 177. Co to jest pięciolinia?

Odpowiedź: Zespół pięciu poziomych linii i czterech pól określających pozycję wysokości dźwięków. Znaczenie pozycji zależy od klucza.

Pytanie 178. Co to jest klucz muzyczny?

Odpowiedź: Symbol przypisujący konkretną wysokość do linii pięciolinii. Klucz wiolinowy, basowy i C zmieniają mapowanie pozycji na nuty.

Pytanie 179. Co to jest linia dodana?

Odpowiedź: Krótka linia rozszerzająca pięciolinie dla dźwięków powyżej lub poniżej jej podstawowego zakresu.

Pytanie 180. Jak pozycja nuty jest zamieniana na wysokość?

Odpowiedź: Szacuje się krok względem linii i pól, uwzględnia klucz, linie dodane, znaki przykluczowe i lokalne znaki chromatyczne, a następnie wyznacza nazwę nuty, oktawę i MIDI.

Pytanie 181. Co to jest numer MIDI nuty?

Odpowiedź: Liczba całkowita reprezentująca wysokość w stroju równomiernie temperowanym. A4 ma numer 69 i częstotliwość 440 Hz.

Pytanie 182. Jak przeliczyć MIDI na częstotliwość?

Odpowiedź:

$$f = 440 \cdot 2^{(m-69)/12}.$$

Każde zwiększenie MIDI o 12 podwaja częstotliwość.

Pytanie 183. Co to jest znak chromatyczny?

Odpowiedź: Krzyżyk, bemol lub kasownik zmieniający wysokość nuty. Może działać lokalnie w takcie lub być częścią znaku przykluczowego.

Pytanie 184. Co to jest znak przykluczowy?

Odpowiedź: Zestaw krzyżyków lub bemoli przy kluczu określający domyślne modyfikacje stopni w danej tonacji.

Pytanie 185. Co to jest metrum?

Odpowiedź: Organizacja pulsu w takty. Licznik określa liczbę jednostek, a mianownik wartość jednostki, np. 4/4 oznacza cztery ćwierćnuty.

Pytanie 186. Co to jest tempo BPM?

Odpowiedź: Liczba uderzeń na minutę. Przy 120 BPM ćwierćnuta, jeżeli jest jednostką pulsu, trwa 0,5 sekundy.

Pytanie 187. Jak przeliczyć beat na sekundy?

Odpowiedź: Dla ćwierćnutowego pulsu:

$$t_{\text{beat}} = \frac{60}{BPM}.$$

Czas zdarzenia to liczba beatów pomnożona przez ten czas.

Pytanie 188. Od czego zależy długość nuty?

Odpowiedź: Od typu notehead, obecności stem, flag i beams, augmentation dot, tupletu, tie oraz kontekstu metrum.

Pytanie 189. Jak działa augmentation dot?

Odpowiedź: Dodaje połowę wartości podstawowej. Ćwierćnuta z kropką trwa $1 + 0,5 = 1,5$ ćwierćnuty.

Pytanie 190. Jak belki określają rytm?

Odpowiedź: Jedna belka zwykle odpowiada ósemkom, dwie szesnastkom itd. Trzeba poprawnie przypisać belkę do laseczek i główek nut.

Pytanie 191. Czym tie różni się od slur?

Odpowiedź: Tie łączy nuty tej samej wysokości i sumuje ich czas. Slur oznacza frazowanie lub legato i może łączyć różne wysokości.

Pytanie 192. Co to jest melisma?

Odpowiedź: Śpiewanie jednej sylaby na kilku nutach. W danych SVS kolejne nuty mogą kontynuować ten sam tekst lub fonem samogłoskowy.

Pytanie 193. Co to jest takt przedtaktowy?

Odpowiedź: Niepełny takt na początku utworu, którego czas często uzupełnia ostatni takt. Nie powinien być automatycznie dopełniany do pełnego metrum bez rozpoznania kontekstu.

Pytanie 194. Co to jest polifonia?

Odpowiedź: Jednoczesne prowadzenie kilku niezależnych głosów. Utrudnia przypisanie nut do osi czasu, tekstu i poszczególnych partii.

Pytanie 195. Co to jest akord?

Odpowiedź: Kilka wysokości rozpoczynających się w przybliżeniu jednocześnie. W wokalnym SVS trzeba wybrać pojedynczy głos lub generować kilka ścieżek.

Pytanie 196. Po co są kreski taktowe?

Odpowiedź: Wyznaczają granice taktów i pomagają grupować zdarzenia zgodnie z metrum. Mogą być mylone z laseczkami.

Pytanie 197. Co to jest synthetic rest?

Odpowiedź: Pauza dodana przez warstwę naprawczą, aby uzupełnić brakujący czas w takcie. Musi być jawnie oznaczona jako inferencja, a nie detekcja z obrazu.

Pytanie 198. Dlaczego nadmiarowego czasu w takcie nie należy dowolnie usuwać?

Odpowiedź: Nie wiadomo, która nuta jest błędna. Automatyczne usunięcie może zniszczyć poprawną muzykę. Bezpieczniej zapisać ostrzeżenie lub zaproponować ręczną korektę.

Pytanie 199. Co to jest dynamic programming w dopasowaniu tekstu?

Odpowiedź: Metoda znajdująca globalnie najtańszą sekwencję przypisań tokenów do nut, uwzględniając koszty dopasowań, pominięć, pauz i melism.

Pytanie 200. Dlaczego proste przypisanie najbliższego tekstu do nuty może zawieść?

Odpowiedź: Tekst może być przesunięty, jedna sylaba może obejmować wiele nut, występują pauzy, kilka zwrotek i błędy OCR. Lokalnie najbliższe przypisanie nie musi być globalnie spójne.

Pytanie 201. Co to jest MusicXML?

Odpowiedź: Strukturalny format wymiany zapisu muzycznego opisujący nuty, rytm, takty, głosy, tekst i oznaczenia wykonawcze. Jest bogatszy semantycznie niż MIDI.

Pytanie 202. Co to jest MIDI?

Odpowiedź: Format zdarzeń sterujących: wysokość, początek, koniec, velocity i instrument. Nie przechowuje pełnego wyglądu partytury ani naturalnego audio.

Pytanie 203. Czym MusicXML różni się od MIDI?

Odpowiedź: MusicXML reprezentuje notację i strukturę partytury. MIDI reprezentuje wykonanie czasowe i komunikaty sterujące. Konwersja pomiędzy nimi może być stratna.

8. Pytania ogólne: audio i SVS

Pytanie 204. Czym SVS różni się od TTS?

Odpowiedź: SVS oprócz tekstu musi realizować jawnie zadaną wysokość, rytm i sposób prowadzenia głosu. Śpiew ma dłuższe samogłoski, szerszy zakres F_0 , vibrato i inne zależności prozodyczne.

Pytanie 205. Co zawiera wejście SVS?

Odpowiedź: Fonemy lub sylaby, początek i koniec zdarzenia, wysokość nuty, pauzy, voiced, głos, styl, tempo oraz opcjonalne cechy wykonawcze.

Pytanie 206. Dlaczego stosuje się fonemy zamiast słów?

Odpowiedź: Fonemy pozwalają generować nowe słowa, dokładniej sterować wymową i czasem poszczególnych głosek oraz lepiej dopasować tekst do nut.

Pytanie 207. Co to jest grafem?

Odpowiedź: Jednostka zapisu, np. litera lub znak. Relacja grafem–fonem nie jest jednoznaczna, szczególnie w języku angielskim.

Pytanie 208. Co to jest fonem?

Odpowiedź: Najmniejsza jednostka dźwiękowa rozróżniająca znaczenie. Model SVS wykorzystuje tokeny fonemowe jako reprezentację wymowy.

Pytanie 209. Co to jest G2P?

Odpowiedź: Grapheme-to-phoneme: algorytm lub model zamieniający zapis słowa na sekwencję fonemów.

Pytanie 210. Co to jest ARPAbet?

Odpowiedź: ASCII-owa reprezentacja angielskich fonemów używana m.in. w CMU Pronouncing Dictionary. Samogłoski mogą zawierać oznaczenie akcentu.

Pytanie 211. Co to jest CMUdict?

Odpowiedź: Słownik wymowy angielskich słów zapisanych w ARPAbet. Pomaga uzyskać poprawniejsze fonemy niż proste reguły literowe.

Pytanie 212. Dlaczego samogłoski otrzymują więcej czasu niż spółgłoski?

Odpowiedź: W śpiewie samogłoska niesie podtrzymywaną wysokość i energię, natomiast większość spółgłosek tworzy krótki atak lub zakończenie.

Pytanie 213. Co to jest waveform?

Odpowiedź: Sekwencja próbek amplitudy sygnału audio w czasie. Jest końcowym formatem generowanym przez wokoder.

Pytanie 214. Co oznacza sample rate 22050 Hz?

Odpowiedź: Audio zawiera 22050 próbek na sekundę. Maksymalna reprezentowalna częstotliwość wynosi w przybliżeniu 11025 Hz.

Pytanie 215. Co to jest częstotliwość Nyquista?

Odpowiedź: Połowa częstotliwości próbkowania. Składowe powyżej niej powodują aliasing, jeżeli nie zostaną odfiltrowane.

Pytanie 216. Co to jest aliasing?

Odpowiedź: Zniekształcenie, w którym częstotliwości powyżej Nyquista pojawiają się jako fałszywe niższe częstotliwości.

Pytanie 217. Co to jest transformata Fouriera?

Odpowiedź: Rozkłada sygnał na składowe częstotliwościowe, opisując amplitudę i fazę sinusoid.

Pytanie 218. Co to jest STFT?

Odpowiedź: Short-Time Fourier Transform liczy transformatę Fouriera w kolejnych nakładających się oknach, tworząc reprezentację czas–częstotliwość.

Pytanie 219. Co oznacza FFT size 1024?

Odpowiedź: Liczbę punktów transformacji. Wpływa na siatkę częstotliwości i koszt obliczeń. Nie jest tożsama z liczbą pasm mel.

Pytanie 220. Co to jest window length?

Odpowiedź: Liczba próbek analizowanych w jednej ramce STFT. Dłuższe okno daje lepszą rozdzielczość częstotliwości kosztem czasu.

Pytanie 221. Co to jest hop length?

Odpowiedź: Przesunięcie pomiędzy kolejnymi oknami. Hop 256 przy 22050 Hz daje krok około 11,6 ms.

Pytanie 222. Co to jest spektrogram?

Odpowiedź: Macierz energii lub amplitudy częstotliwości w kolejnych chwilach czasu.

Pytanie 223. Co to jest skala mel?

Odpowiedź: Nieliniowa skala częstotliwości przybliżająca percepcję człowieka: większa dokładność dla niższych częstotliwości i silniejsze grupowanie wysokich.

Pytanie 224. Co to jest mel-spektrogram?

Odpowiedź: Spektrogram, którego częstotliwości są rzutowane na bank filtrów mel. Jest standardową reprezentacją pośrednią w TTS i SVS.

Pytanie 225. Dlaczego stosuje się log-mel?

Odpowiedź: Logarytm kompresuje duży zakres energii i lepiej odpowiada percepcji głośności. Ułatwia również uczenie modelu.

Pytanie 226. Czego mel-spektrogram nie przechowuje?

Odpowiedź: Nie przechowuje pełnej informacji fazowej i redukuje szczegóły widma. Dlatego rekonstrukcja waveformu nie jest jednoznaczna.

Pytanie 227. Co to jest F_0 ?

Odpowiedź: Częstotliwość podstawowa sygnału okresowego, związana z postrzeganą wysokością głosu.

Pytanie 228. Czym F_0 różni się od formantu?

Odpowiedź: F_0 wynika z okresowości źródła głosu i określa pitch. Formanty to rezonanse traktu głosowego kształtujące samogłoskę i barwę.

Pytanie 229. Co to jest cent?

Odpowiedź: Logarytmiczna jednostka interwału. 100 centów to półton, 1200 centów oktawa.

Pytanie 230. Jak liczy się błąd wysokości w centach?

Odpowiedź:

$$e = 1200 \log_2 \left(\frac{\hat{F}_0}{F_0} \right).$$

MAE wykorzystuje wartość bezwzględną tego błędu.

Pytanie 231. Dlaczego błąd w hercach byłby mniej muzyczny?

Odpowiedź: Ta sama różnica Hz oznacza inny interwał przy niskiej i wysokiej częstotliwości. Centy mierzą względną zmianę wysokości.

Pytanie 232. Co to jest voiced/unvoiced?

Odpowiedź: Informacja, czy ramka ma regularną strukturę okresową i zdefiniowane F_0 . Spółgłoski bezdźwięczne i cisha są unvoiced.

Pytanie 233. Dlaczego F_0 mierzy się tylko na ramkach voiced?

Odpowiedź: Dla ciszy i szumu bezdźwięcznego częstotliwość podstawowa nie jest zdefiniowana. Wymuszenie wartości prowadziłoby do sztucznych błędów.

Pytanie 234. Co to jest pYIN?

Odpowiedź: Probabilistyczny algorytm estymacji F_0 , rozszerzający YIN o model probabilistyczny i śledzenie wysokości w czasie.

Pytanie 235. Jakie błędy może popełniać estymator F_0 ?

Odpowiedź: Błędy oktafowe, utrata detekcji, błędna klasyfikacja voiced/unvoiced oraz śledzenie harmonicznej zamiast częstotliwości podstawowej.

Pytanie 236. Co to jest energia ramki?

Odpowiedź: Miara amplitudy lub mocy sygnału w krótkim oknie. W SVS steruje obwiednią głośności i dynamiką.

Pytanie 237. Co to jest prosodia?

Odpowiedź: Czas, akcent, intonacja, energia, rytm, vibrato, frazowanie i inne cechy wykonania ponad samą sekwencją fonemów.

Pytanie 238. Co to jest embedding?

Odpowiedź: Uczony wektor reprezentujący dyskretny token, głos, styl lub język. Podobne elementy mogą otrzymać podobne reprezentacje.

Pytanie 239. Jak działa self-attention?

Odpowiedź: Każda pozycja tworzy query, key i value. Iloczyn query–key wyznacza wagę, którymi agregowane są values innych pozycji.

Pytanie 240. Co to jest multi-head attention?

Odpowiedź: Kilka niezależnych mechanizmów attention analizujących różne podprzestrzenie cech i typy zależności. Wyniki głów są łączone.

Pytanie 241. Dlaczego Transformer potrzebuje maski paddingu?

Odpowiedź: Sekwencje w batchu mają różne długości. Maski uniemożliwia attention korzystanie z dopełnionych, sztucznych pozycji.

Pytanie 242. Co to jest sinusoidalne kodowanie pozycyjne?

Odpowiedź: Deterministyczne wektory sinusów i cosinusów o różnych częstotliwościach dodawane do cech, aby model znał kolejność i względne odległości.

Pytanie 243. Co to jest length regulator?

Odpowiedź: Mechanizm rozszerzający reprezentację zdarzenia do liczby ramek wynikającej z duration. Powtarza wektor fonemu lub nuty zgodnie z czasem.

Pytanie 244. Czym model autoregresyjny różni się od nieautoregresyjnego?

Odpowiedź: Autoregresyjny generuje kolejne elementy zależnie od poprzednich i jest wolniejszy. Nieautoregresyjny generuje wiele pozycji równolegle, zwykle potrzebując jawnych czasów.

Pytanie 245. Co to jest Conformer?

Odpowiedź: Architektura łącząca self-attention dla globalnego kontekstu z modułem konwolucyjnym dla lokalnych zależności czasowych.

Pytanie 246. Co to jest depthwise convolution?

Odpowiedź: Osobna konwolucja dla każdego kanału. Jest tańsza od pełnej konwolucji i w Conformerze modeluje lokalny kontekst czasowy.

Pytanie 247. Co to jest GLU?

Odpowiedź: Gated Linear Unit dzieli kanały na część treści i bramkę sigmoid, która kontroluje przepływ informacji.

Pytanie 248. Co to jest score F_0 ?

Odpowiedź: Krzywa częstotliwości podstawowej wynikająca bezpośrednio z wysokości nut i ich czasu, po uwzględnieniu transpozycji i przejść.

Pytanie 249. Co to jest predicted F_0 ?

Odpowiedź: Krzywa przewidziana przez model akustyczny, zwykle jako odchylenie względem partytury. Może zawierać mikroprozodię, ale też błędy wysokości.

Pytanie 250. Co to jest blend F_0 ?

Odpowiedź: Mieszanka score i predicted F_0 . Ma łączyć kontrolę melodii z naturalnością, lecz w eksperymencie dawała większy błąd niż score.

Pytanie 251. Co to jest score-relative F_0 ?

Odpowiedź: Model przewiduje odchylenie w centach względem wysokości partytury, zamiast częstotliwości bezwzględnej.

Pytanie 252. Dlaczego ogranicza się maksymalne odchylenie F_0 ?

Odpowiedź: Chroni melodię przed dużymi błędami i stabilizuje trening. Model nadal może przewidywać vibrato i łagodne przejścia.

Pytanie 253. Co to jest teacher forcing?

Odpowiedź: Podawanie wartości referencyjnej zamiast własnej predykcji modelu jako wejścia kolejnego etapu podczas treningu.

Pytanie 254. Co to jest exposure bias?

Odpowiedź: Różnica pomiędzy treningiem z idealnymi wejściami a inferencją z własnymi błędnymi predykcjami. Może powodować kumulowanie błędów.

Pytanie 255. Co to jest postnet?

Odpowiedź: Sieć konwolucyjna przewidująca residualną poprawkę do bazowego mel-spektrogramu.

Pytanie 256. Co to jest residualny mel refiner?

Odpowiedź: Dodatkowa sieć korygująca mel po głównym modelu i postnecie. Uczy się poprawki, a nie całej reprezentacji od zera.

Pytanie 257. Dlaczego residualne wyjście inicjalizuje się zerami?

Odpowiedź: Na początku refiner nie zmienia istniejącej predykcji. Trening może stopniowo nauczyć bezpieczną poprawkę bez natychmiastowego pogorszenia bazowego modelu.

Pytanie 258. Co to jest wokoder?

Odpowiedź: Model lub algorytm zamieniający reprezentację akustyczną, np. mel-spektrogram, na waveform.

Pytanie 259. Jak działa HiFi-GAN?

Odpowiedź: Generator zwiększa rozdzielczość czasową mel do waveformu, a dyskryminatory wielookresowe i wieloskalowe uczą go realistycznej periodyczności i szczegółów sygnału.

Pytanie 260. Co to jest GAN?

Odpowiedź: Układ generatora i dyskryminatora. Generator tworzy próbki, a dyskryminator odróżnia je od prawdziwych. Oba modele uczą się w konkurencyjnym procesie.

Pytanie 261. Co to jest generator adversarial loss?

Odpowiedź: Kara dla generatora, gdy dyskryminator rozpoznaje wygenerowany sygnał jako fałszywy.

Pytanie 262. Co to jest discriminator loss?

Odpowiedź: Kara, gdy dyskryminator źle klasyfikuje prawdziwe lub wygenerowane próbki.

Pytanie 263. Co to jest feature matching loss?

Odpowiedź: Różnica pomiędzy pośrednimi aktywacjami dyskryminatora dla realnego i generowanego audio. Stabilizuje GAN i promuje zgodność strukturalną.

Pytanie 264. Co to jest Multi-Period Discriminator?

Odpowiedź: Zestaw dyskryminatorów analizujących waveform po ułożeniu go według różnych okresów. Jest wrażliwy na strukturę harmoniczną i periodyczność głosu.

Pytanie 265. Co to jest Multi-Scale Discriminator?

Odpowiedź: Analizuje sygnał przy kilku rozdzielczościach czasowych, dzięki czemu widzi lokalne detale i szerszą obwiednię.

Pytanie 266. Co to jest mel sub-band discriminator?

Odpowiedź: Dyskryminator analizujący oddzielne zakresy pasm mel. Może zwiększyć nacisk na wysokie częstotliwości i lokalny detal widma.

Pytanie 267. Co to jest multi-resolution STFT loss?

Odpowiedź: Porównanie spektrogramów przy kilku rozmiarach FFT, oknach i hopach. Łączy ocenę lokalnego i szerszego kontekstu czasowo-częstotliwościowego.

Pytanie 268. Co to jest source-filter model głosu?

Odpowiedź: Model, w którym źródło pobudzenia krtaniowego jest filtrowane przez trakt głosowy. Źródło kontroluje pitch, a filtr głównie barwę i formanty.

Pytanie 269. Jak działa harmoniczne źródło w wokoderze?

Odpowiedź: Z F_0 obliczana jest faza sinusoidy i jej harmoniczne. Są one maskowane dla ramek unvoiced i dodawane jako warunek na etapach generatora.

Pytanie 270. Dlaczego ogranicza się harmoniczne względem Nyquista?

Odpowiedź: Harmoniczne powyżej Nyquista powodowałyby aliasing i fałszywe składowe.

Pytanie 271. Co to jest pitch-shift sensitivity loss?

Odpowiedź: Strata wymagająca, aby celowa zmiana warunku F_0 powodowała mierzalną zmianę wyniku. Zapobiega ignorowaniu pitch przez wokoder.

Pytanie 272. Co to jest acoustic–vocoder mismatch?

Odpowiedź: Wokoder trenuje się na prawdziwych melach, ale w inferencji dostaje niedoskonałe mele przewidywane. Różnica rozkładu może pogarszać audio.

Pytanie 273. Jak zmniejszono acoustic–vocoder mismatch w pracy?

Odpowiedź: Wokoder dostrojono na mel-spektrogramach generowanych przez finalny model akustyczny, a nie wyłącznie na reprezentacjach referencyjnych.

Pytanie 274. Co to jest audio-proxy validation?

Odpowiedź: Model akustyczny generuje mel, wokoder generuje audio, a z audio ponownie liczy się mel i porównuje z referencją. Metryka obejmuje oba modele.

Pytanie 275. Dlaczego audio-proxy nadal nie zastępuje odsłuchu?

Odpowiedź: Dwa sygnały o podobnym mel mogą różnić się fazą, artefaktami, zrozumiałością, naturalnością i barwą. Metryka numeryczna jest tylko przybliżeniem percepcji.

Pytanie 276. Co to jest vibrato?

Odpowiedź: Okresowa modulacja F_0 , opisywana szybkością w Hz i głębokością w centach. Zbyt duże vibrato brzmi niestabilnie, zbyt małe może być niesłyszalne.

Pytanie 277. Co to jest pitch drift?

Odpowiedź: Powolne odchylenie wysokości w czasie. Niewielkie może zwiększać naturalność, duże brzmi jak fałszowanie.

Pytanie 278. Co to jest onset pitch scoop?

Odpowiedź: Krótkie rozpoczęcie nuty poniżej lub powyżej wysokości docelowej i dojście do niej. Jest cechą wykonawczą, ale wymaga ostrożnej kontroli.

Pytanie 279. Dlaczego transpozycja może być potrzebna?

Odpowiedź: Melodia może wychodzić poza zakres wysokości widziany dla danego głosu podczas treningu. Transpozycja przenosi ją do stabilniejszego zakresu.

Pytanie 280. Jaka jest wada transpozycji?

Odpowiedź: Zmienia tonację i może być muzycznie niepożądana. Przy bezpośrednim pitch-shifcie audio może też zmieniać formanty i barwę.

Pytanie 281. Co to jest MOS?

Odpowiedź: Mean Opinion Score: średnia subiektywna ocena, zwykle w skali 1–5, np. naturalności audio.

Pytanie 282. Co to jest CMOS?

Odpowiedź: Comparative MOS: ocena preferencji lub różnicy pomiędzy dwiema próbkami, np. od -3 do +3.

Pytanie 283. Jak poprawnie wykonać test percepcyjny?

Odpowiedź: Zaślepić i zrandomizować próbki, użyć wielu utworów i słuchaczy, rozdzielić kryteria oceny, zebrać metadane o słuchaczach oraz raportować średnie, wariancję i przedziały ufności.

9. Pytania o integrację, testowanie i rozwój systemu

Pytanie 284. Po co zapisuje się konfigurację razem z checkpointem?

Odpowiedź: Wagi mają sens tylko w połączeniu z architekturą, vocabem, normalizacją, listą głosów, stylów i parametrami cech. Bez tego inferencja może być niezgodna.

Pytanie 285. Dlaczego vocab.json musi pasować do checkpointu?

Odpowiedź: Indeksy embeddingów odpowiadają konkretnym tokenom. Inny vocab przypisałby tym samym indeksom inne fonemy.

Pytanie 286. Dlaczego stats.json musi pasować do modelu?

Odpowiedź: Model był uczony na cechach znormalizowanych konkretną średnią i odchyleniem. Inne statystyki zmieniają skalę wejścia i wyjścia.

Pytanie 287. Co to jest checkpoint compatibility?

Odpowiedź: Zgodność wag z architekturą, wymiarami, słownikiem, normalizacją i wersją przygotowania danych.

Pytanie 288. Co to jest test jednostkowy?

Odpowiedź: Test małego fragmentu logiki w izolacji, np. konwersji osi czasu, kodowania tokenów lub naprawy taktu.

Pytanie 289. Co to jest test integracyjny?

Odpowiedź: Sprawdza współpracę kilku modułów i zgodność ich kontraktów, np. OMR–Score IR–SVS CSV.

Pytanie 290. Co to jest test end-to-end?

Odpowiedź: Uruchamia pełny przepływ od wejścia użytkownika do końcowego wyniku.

Pytanie 291. Co to jest test regresji?

Odpowiedź: Sprawdza, czy wcześniej działający przypadek nadal daje oczekiwany wynik po zmianach kodu lub modelu. Golden set jest naturalną podstawą takich testów.

Pytanie 292. Dlaczego oracle jest przydatne w testach?

Odpowiedź: Pozwala zastąpić wynik jednego modułu poprawną referencją i sprawdzić, czy problem pozostaje w dalszej części pipeline’u.

Pytanie 293. Jak mierzyć propagację błędów?

Odpowiedź: Porównywać warianty z kolejno zastępowanymi modułami oracle i mierzyć zmianę jakości Score IR, MIDI i audio.

Pytanie 294. Jak przekazywać niepewność pomiędzy modułami?

Odpowiedź: Zachowywać confidence, alternatywne hipotezy i źródła decyzji zamiast tylko twardej etykiety. Warstwa interpretacji może wykorzystywać reguły i kontekst do wyboru hipotezy.

Pytanie 295. Co to jest kalibracja modelu?

Odpowiedź: Zgodność confidence z rzeczywistą częstością poprawnych predykcji. Model z confidence 0,8 powinien mieć około 80% poprawnych przypadków w tej grupie.

Pytanie 296. Jak można umożliwić ręczną korektę?

Odpowiedź: Interfejs może pozwalać przesuwając boxy, zmieniać klasy, wysokości, czasy i tekst, a następnie ponownie generować tylko Score IR i audio bez uruchamiania modeli obrazu.

Pytanie 297. Jak poprawić odporność na nowe wydawnictwa nutowe?

Odpowiedź: Zebrać dane z różnych źródeł, zastosować fine-tuning, style augmentation, normalizację odstępu pięciolinii, aktywne uczenie i analizę błędów per domena.

Pytanie 298. Jak poprawić wydajność pipeline’u?

Odpowiedź: Batchowanie kafli i cropów, mniejsze lub skompresowane modele, cache, mixed precision, równoległość etapów niezależnych, ONNX/TensorRT oraz adaptacyjne pomijanie zbędnych modułów.

Pytanie 299. Jakie byłyby następne trzy najważniejsze eksperymenty?

Odpowiedź: Real-world test set partytur wokalnych; uczciwy wieloseedowy protokół OMR z osobnym validation/test; zaślepiona ewaluacja percepcyjna SVS z baseline’ami.

10. Słownik najważniejszych pojęć

10.1. Uczenie maszynowe i eksperymenty

Ablation study

Definicja: Kontrolowane usunięcie lub zmiana składnika modelu.

Jak działa / dlaczego jest ważne: Pozwala przypisać zmianę wyniku konkretnemu elementowi. Przykładem jest porównanie score, blend i predicted F_0 .

Accuracy

Definicja: Odsetek poprawnych klasyfikacji.

Jak działa / dlaczego jest ważne: Jest intuicyjna, ale bywa myląca przy niezbalansowanych klasach. Nie była wystarczająca dla segmentacji tekstu ani gęstej detekcji OMR.

Augmentacja danych

Definicja: Transformacja próbki treningowej zachowująca jej semantyczną etykietę.

Jak działa / dlaczego jest ważne: Poszerza rozkład danych i ogranicza overfitting. W OMR symulowała m.in. skan, zdjęcie, rotację, skalę, kompresję i atrament.

Baseline

Definicja: Model lub metoda odniesienia.

Jak działa / dlaczego jest ważne: Pozwala ocenić, czy nowe rozwiązanie jest rzeczywiście lepsze. Musi być oceniany na tym samym podziale i protokole.

Batch

Definicja: Grupa próbek używana do jednego obliczenia gradientu.

Jak działa / dlaczego jest ważne: Wpływa na pamięć, szybkość i stabilność statystyk. OMR używał batch size 1.

Checkpoint

Definicja: Zapis stanu modelu w określonym momencie treningu.

Jak działa / dlaczego jest ważne: Powinien zawierać lub wskazywać architekturę, wagi, konfigurację i meta-dane. Sam plik wag nie zawsze wystarcza do poprawnej inferencji.

Class imbalance

Definicja: Nierówny rozkład liczby przykładów klas.

Jak działa / dlaczego jest ważne: Powoduje dominację tła lub częstych klas. Ogranicza się go ważeniem strat, samplingiem, focal loss i odpowiednimi metrykami.

Data leakage

Definicja: Nieuprawnione wykorzystanie informacji z walidacji lub testu.

Jak działa / dlaczego jest ważne: Prowadzi do optymistycznego wyniku. W pracy ograniczeniem było użycie testu DeepScoresV2 do wyboru checkpointu.

Domain shift

Definicja: Różnica rozkładu danych treningowych i docelowych.

Jak działa / dlaczego jest ważne: Najważniejsze przykłady to ogólne dokumenty kontra partytury oraz syntetyczne DeepScoresV2 kontra skany i zdjęcia użytkowników.

Early stopping

Definicja: Zatrzymanie treningu po braku poprawy.

Jak działa / dlaczego jest ważne: Ogranicza przeuczenie i koszt, ale działa poprawnie tylko przy reprezentatywnym zbiorze walidacyjnym.

Epoch

Definicja: Jedno pełne przejście po zbiorze treningowym.

Jak działa / dlaczego jest ważne: Nie jest uniwersalną jednostką kosztu, ponieważ liczba optimizer steps zależy od liczby próbek i batch size.

Fine-tuning

Definicja: Dalsze uczenie wstępnie wytrenowanego modelu.

Jak działa / dlaczego jest ważne: Pozwala dostosować model do nowej domeny, np. OCR dokumentowy do tekstu na partyturach.

Funkcja straty

Definicja: Różniczkowalna miara błędu używana do aktualizacji wag.

Jak działa / dlaczego jest ważne: Może być kombinacją wielu składników i nie musi odpowiadać końcowej metryce.

Generalizacja

Definicja: Zdolność działania na nowych danych.

Jak działa / dlaczego jest ważne: Nie można jej ocenić na próbkach użytych do strojenia. Wymaga reprezentatywnego testu.

Golden set

Definicja: Mały, ręcznie kontrolowany zestaw referencyjny.

Jak działa / dlaczego jest ważne: Służy do diagnostyki i regresji. W pracy zawiera dziesięć utworów z oracle Score IR i SVS CSV.

Gradient

Definicja: Wektor pochodnych straty względem parametrów.

Jak działa / dlaczego jest ważne: Wskazuje kierunek najszybszego wzrostu straty; optymalizator wykonuje krok przeciwny.

Hiperparametr

Definicja: Ustawienie wybierane poza uczeniem wag.

Jak działa / dlaczego jest ważne: Przykłady: learning rate, stride, tile size, overlap, próg confidence, liczba warstw.

Inference

Definicja: Użycie wytrenowanego modelu do generowania predykcji.

Jak działa / dlaczego jest ważne: Model działa zwykle bez gradientów i z wyłączonym dropoutem.

Learning rate

Definicja: Wielkość kroku optymalizatora.

Jak działa / dlaczego jest ważne: Zbyt wysoki destabilizuje trening, zbyt niski spowalnia go lub zatrzymuje w słabym minimum.

Metryka

Definicja: Miara używana do oceny modelu.

Jak działa / dlaczego jest ważne: Powinna odpowiadać celowi zadania. W pracy różne moduły wymagały IoU, CER, mAP i błędu F_0 .

Mixed precision

Definicja: Łączenie obliczeń w niższej i wyższej precyzji.

Jak działa / dlaczego jest ważne: Zmniejsza użycie pamięci i przyspiesza GPU, wymagając skalowania gradientu dla stabilności.

Optimizer

Definicja: Algorytm aktualizacji wag.

Jak działa / dlaczego jest ważne: W pracy stosowano m.in. Adam i AdamW. Wykorzystuje gradient i stan, np. momentum.

Oracle

Definicja: Ręcznie poprawne wejście zastępujące wynik wcześniejszego modułu.

Jak działa / dlaczego jest ważne: Umożliwia izolację błędów. Oracle SVS bada syntezę bez błędów OCR, OMR i Score IR.

Overfitting

Definicja: Nadmierne dopasowanie do treningu.

Jak działa / dlaczego jest ważne: Model poprawia wynik treningowy, ale nie generalizuje. Ograniczają go dane, augmentacje i regularyzacja.

Parameter

Definicja: Wartość uczona przez model.

Jak działa / dlaczego jest ważne: Przykłady to wagi konwolucji, embeddingi i biasy. Należy odróżnić je od hiperparametrów.

Seed

Definicja: Początkowy stan generatora losowego.

Jak działa / dlaczego jest ważne: Pomaga odtwarzać run. Wiele seedów jest potrzebnych do oceny stabilności wyników.

Test set

Definicja: Zbiór do końcowej oceny.

Jak działa / dlaczego jest ważne: Nie powinien wpływać na wybór modelu. Inaczej wynik przestaje być bezstronny.

Train set

Definicja: Zbiór używany do uczenia wag.

Jak działa / dlaczego jest ważne: Model wielokrotnie widzi te próbki podczas optymalizacji.

Transfer learning

Definicja: Przeniesienie wiedzy z wcześniej wytrenowanego modelu.

Jak działa / dlaczego jest ważne: Może poprawić uczenie na małym zbiorze, choć domena źródłowa może być odległa.

Underfitting

Definicja: Niedostateczne dopasowanie nawet do treningu.

Jak działa / dlaczego jest ważne: Może wynikać ze zbyt prostego modelu, słabej optymalizacji lub za krótkiego treningu.

Validation set

Definicja: Zbiór do wyboru hiperparametrów i checkpointu.

Jak działa / dlaczego jest ważne: Można go wykorzystywać wielokrotnie, ale końcowa ocena wymaga osobnego testu.

Weight decay

Definicja: Regularyzacja zmniejszająca duże wagi.

Jak działa / dlaczego jest ważne: W AdamW jest oddzielona od adaptacyjnego gradientu.

10.2. Widzenie komputerowe, segmentacja i OCR

Anchor

Definicja: Wstępny box używany przez detektor.

Jak działa / dlaczego jest ważne: RPN ocenia objectness i przewiduje korektę. Rozmiary i proporcje muszą pasować do symboli.

Attention gate

Definicja: Mechanizm ważący cechy skip connection.

Jak działa / dlaczego jest ważne: W Attention U-Net tłumii tło i wzmacnia regiony istotne dla decodera.

BatchNorm

Definicja: Normalizacja wykorzystująca statystyki batcha.

Jak działa / dlaczego jest ważne: Jest skuteczna dla większych batchy, ale niestabilna przy batch size 1.

Bounding box

Definicja: Prostokąt opisujący położenie obiektu.

Jak działa / dlaczego jest ważne: Może być osiowy lub zorientowany. Jest prosty, ale dla cienkich symboli obejmuje dużo tła.

BCE

Definicja: Binary Cross-Entropy.

Jak działa / dlaczego jest ważne: Strata klasyfikacji binarnej. W lokalizacji tekstu była stosowana bezpośrednio na logits z większą wagą klasy tekstowej.

CER

Definicja: Character Error Rate.

Jak działa / dlaczego jest ważne: Znormalizowana odległość edycyjna na znakach. Niższy wynik oznacza lepszy OCR.

CNN

Definicja: Convolutional Neural Network.

Jak działa / dlaczego jest ważne: Uczy lokalne filtry i hierarchiczne mapy cech obrazu. Jest podstawą U-Net, CRNN i backbone OMR.

CTC

Definicja: Connectionist Temporal Classification.

Jak działa / dlaczego jest ważne: Umożliwia uczenie sekwencji bez anotacji pozycji znaków, sumując monotoniczne ścieżki z blankami i powtórzeniami.

Dice

Definicja: Miara nakładania dwóch masek.

Jak działa / dlaczego jest ważne: $2TP/(2TP + FP + FN)$. Jest równoważna pikselowemu F1 przy tej samej agregacji.

Dylatacja

Definicja: Operacja morfologiczna rozszerzająca region maski.

Jak działa / dlaczego jest ważne: Łączy fragmenty i wzmacnia cienkie elementy, ale może scalać różne obiekty.

Encoder–decoder

Definicja: Architektura kompresująca wejście do reprezentacji i rekonstruująca wyjście.

Jak działa / dlaczego jest ważne: U-Net używa jej dla maski, a TrOCR dla przejścia obraz–tekst.

Erozja

Definicja: Operacja morfologiczna zmniejszająca region maski.

Jak działa / dlaczego jest ważne: Usuwa szum i rozdziela połączenia, ale może zniszczyć cienkie elementy.

Exact match

Definicja: Metryka pełnej zgodności napisu.

Jak działa / dlaczego jest ważne: Jest rygorystyczna: jeden błąd oznacza niepoprawną próbkę.

F1

Definicja: Średnia harmoniczna precision i recall.

Jak działa / dlaczego jest ważne: Równoważy fałszywe predykcje i pominięcia.

FPN

Definicja: Feature Pyramid Network.

Jak działa / dlaczego jest ważne: Łączy semantykę głębokich cech z wysoką rozdzielczością płytszych poziomów.

GroupNorm

Definicja: Normalizacja kanałów w grupach.

Jak działa / dlaczego jest ważne: Nie zależy od batch size i została użyta we własnym backbone OMR.

IoU

Definicja: Intersection over Union.

Jak działa / dlaczego jest ważne: Przecięcie podzielone przez sumę obszarów. Używane dla masek i boxów.

LSTM

Definicja: Long Short-Term Memory.

Jak działa / dlaczego jest ważne: RNN z bramkami kontrolującymi pamięć. BiLSTM modeluje tekst z obu kierunków.

Logit

Definicja: Nieznormalizowany wynik przed sigmoid lub softmax.

Jak działa / dlaczego jest ważne: BCEWithLogits łączy sigmoid i cross-entropy w stabilny numeryczny sposób.

Maska binarna

Definicja: Obraz dwóch klas.

Jak działa / dlaczego jest ważne: W lokalizacji oznacza piksele tekstu i tła.

NMS

Definicja: Non-Maximum Suppression.

Jak działa / dlaczego jest ważne: Usuwa nakładające się predykcje, pozostawiając te o najwyższym confidence.

OCR

Definicja: Optical Character Recognition.

Jak działa / dlaczego jest ważne: Rozpoznawanie tekstu z obrazu. W pracy działa na cropach wskazanych przez lokalizację.

OMR

Definicja: Optical Music Recognition.

Jak działa / dlaczego jest ważne: Rozpoznawanie zapisu muzycznego, obejmujące percepcję symboli i rekonstrukcję semantyki.

Oriented bounding box

Definicja: Box lub wielokąt zgodny z orientacją obiektu.

Jak działa / dlaczego jest ważne: Lepszy dla belek, łuków i cienkich symboli niż prostokąt osiowy.

Output stride

Definicja: Skala zmniejszenia mapy cech względem obrazu.

Jak działa / dlaczego jest ważne: Mniejszy stride zachowuje szczegóły, ale zwiększa koszt.

Precision

Definicja: Odsetek predykcji, które są poprawne.

Jak działa / dlaczego jest ważne: $TP/(TP + FP)$. Wysokie precision oznacza mało false positives.

Recall

Definicja: Odsetek prawdziwych obiektów, które wykryto.

Jak działa / dlaczego jest ważne: $TP/(TP + FN)$. Wysoki recall oznacza mało pominąć.

ResNet

Definicja: Sieć z residual connections.

Jak działa / dlaczego jest ważne: Ułatwia uczenie głębokich modeli. W pracy wykorzystano własne bloki residualne w OCR.

RPN

Definicja: Region Proposal Network.

Jak działa / dlaczego jest ważne: Pierwszy etap Faster R-CNN generujący regiony kandydackie.

RoIAlign

Definicja: Ekstrakcja cech regionu bez agresywnej kwantyzacji współrzędnych.

Jak działa / dlaczego jest ważne: Zapewnia mapę stałego rozmiaru dla klasyfikacji i regresji boxa.

Segmentacja instancyjna

Definicja: Maska osobno dla każdego obiektu.

Jak działa / dlaczego jest ważne: Łączy lokalizację instancji z dokładnym kształtem.

Segmentacja semantyczna

Definicja: Klasa dla każdego piksela.

Jak działa / dlaczego jest ważne: W pracy używana do lokalizacji tekstu.

Skip connection

Definicja: Połączenie omijające część warstw.

Jak działa / dlaczego jest ważne: W U-Net przekazuje detal przestrzenny, a w ResNet ułatwia przepływ gradientu.

Tiling

Definicja: Dzielenie dużego obrazu na kafle.

Jak działa / dlaczego jest ważne: Pozwala zachować wysoką rozdzielczość symboli OMR.

Transformer

Definicja: Architektura oparta na self-attention.

Jak działa / dlaczego jest ważne: Modeluje zależności globalne i wymaga informacji pozycyjnej.

U-Net

Definicja: Konwolucyjny encoder–decoder ze skip connections.

Jak działa / dlaczego jest ważne: Klasyczna architektura precyzyjnej segmentacji.

WER

Definicja: Word Error Rate.

Jak działa / dlaczego jest ważne: Odległość edycyjna liczona na słowach. Przydatna dla pełnych linii, mniej szczegółowa od CER dla sylab.

10.3. Detekcja i metryki OMR

AP

Definicja: Average Precision.

Jak działa / dlaczego jest ważne: Pole pod krzywą precision–recall dla klasy i progu IoU.

AP50

Definicja: AP przy IoU 0,50.

Jak działa / dlaczego jest ważne: Łagodniej ocenia lokalizację niż AP75.

AP75

Definicja: AP przy IoU 0,75.

Jak działa / dlaczego jest ważne: Wymaga precyzyjniejszego dopasowania boxa.

Aspect ratio

Definicja: Stosunek szerokości do wysokości boxa.

Jak działa / dlaczego jest ważne: W OMR musi obejmować zarówno cienkie pionowe, jak i długie poziome symbole.

Confidence threshold

Definicja: Minimalny score pozostawianej predykcji.

Jak działa / dlaczego jest ważne: Steruje kompromisem precision–recall i liczbą boxów przekazywanych dalej.

Faster R-CNN

Definicja: Dwustopniowy detektor.

Jak działa / dlaczego jest ważne: RPN generuje proposals, a drugi etap klasyfikuje i poprawia boxy.

mAP

Definicja: Mean Average Precision.

Jak działa / dlaczego jest ważne: Średnia AP po klasach i progach. W pracy użyto zakresu IoU 0,50–0,95.

Micro-anchor

Definicja: Bardzo mały anchor.

Jak działa / dlaczego jest ważne: Potrzebny dla kilkupikselowych symboli nutowych.

Objectness

Definicja: Ocena, czy region zawiera obiekt.

Jak działa / dlaczego jest ważne: RPN przewiduje ją niezależnie od klasy szczegółowej.

Support

Definicja: Liczba przykładów klasy.

Jak działa / dlaczego jest ważne: Wpływa na stabilność metryki, ale nie wyjaśnia samodzielnie trudności klasy.

10.4. Muzyka, reprezentacja i Score IR

Akord

Definicja: Kilka jednoczesnych wysokości.

Jak działa / dlaczego jest ważne: Wymaga rozdzielenia głosów lub kilku ścieżek wokalnych.

Augmentation dot

Definicja: Kropka przedłużająca wartość rytmiczną.

Jak działa / dlaczego jest ważne: Dodaje połowę wartości podstawowej nuty lub pauzy.

Beam

Definicja: Belka łącząca laseczki nut.

Jak działa / dlaczego jest ważne: Liczba poziomów belki pomaga wyznaczyć czas trwania.

Clef

Definicja: Klucz muzyczny.

Jak działa / dlaczego jest ważne: Określa mapowanie pozycji na pięciolinii na wysokość.

Key signature

Definicja: Znak przykluczowy.

Jak działa / dlaczego jest ważne: Ustala domyślne krzyżyki lub bemole dla stopni skali.

Ledger line

Definicja: Linia dodana.

Jak działa / dlaczego jest ważne: Rozszerza zakres pięciolinii i jest ważna dla nut skrajnych.

Melisma

Definicja: Jedna sylaba śpiewana na kilku nutach.

Jak działa / dlaczego jest ważne: Wymaga kontynuacji tekstu i odpowiedniego przydziału fonemów.

Metrum

Definicja: Organizacja beatów w takty.

Jak działa / dlaczego jest ważne: Pozwala walidować sumę czasów i budować oś muzyczną.

MIDI

Definicja: Format zdarzeń muzycznych.

Jak działa / dlaczego jest ważne: Przechowuje pitch i czas, ale nie pełną notację ani audio.

MusicXML

Definicja: Strukturalny format notacji muzycznej.

Jak działa / dlaczego jest ważne: Przechowuje bogatszą semantykę partytury niż MIDI.

Notehead

Definicja: Główka nuty.

Jak działa / dlaczego jest ważne: Jej typ i pozycja są podstawą wysokości i wartości rytmicznej.

Pickup measure

Definicja: Takt przedtaktowy.

Jak działa / dlaczego jest ważne: Niepełny takt początku utworu wymagający osobnego traktowania.

Polifonia

Definicja: Wiele niezależnych głosów jednocześnie.

Jak działa / dlaczego jest ważne: Utrudnia przypisanie rytmu, relacji i tekstu.

Score IR

Definicja: Jawna reprezentacja pośrednia partytury.

Jak działa / dlaczego jest ważne: Łączy symbole, geometrię, zdarzenia, relacje, warningi i naprawy oraz zasila eksporty.

Slur

Definicja: Łuk frazowy.

Jak działa / dlaczego jest ważne: Oznacza legato lub frazowanie i może łączyć różne wysokości.

Stem

Definicja: Laseczka nuty.

Jak działa / dlaczego jest ważne: Łączy notehead z flag lub beam i jest ważna dla rytmu.

Synthetic rest

Definicja: Pauza dodana przez reguły naprawcze.

Jak działa / dlaczego jest ważne: Uzupełnia czas taktu, ale musi być jawnie oznaczona jako inferencja.

Tie

Definicja: Łuk przedłużający.

Jak działa / dlaczego jest ważne: Łączy tę samą wysokość i sumuje czas bez ponownej artykulacji tekstu.

10.5. Audio i SVS

Acoustic model

Definicja: Model mapujący dane symboliczne na reprezentację akustyczną.

Jak działa / dlaczego jest ważne: W pracy przewiduje mel-spektrogram, F_0 , energię i duration.

Aliasing

Definicja: Fałszywe częstotliwości powstałe przez niedostateczne próbkowanie.

Jak działa / dlaczego jest ważne: Harmoniczne źródła muszą być ograniczane poniżej Nyquista.

ARPAbet

Definicja: ASCII-owy zapis angielskich fonemów.

Jak działa / dlaczego jest ważne: Ułatwia tokenizację wymowy i współpracę z CMUdict.

Audio-proxy

Definicja: Walidacja toru mel–wokoder–waveform–mel.

Jak działa / dlaczego jest ważne: Mierzy połączony błąd modelu akustycznego i wokodera.

Cent

Definicja: Jednostka interwału muzycznego.

Jak działa / dlaczego jest ważne: 100 centów to półton. Umożliwia porównywanie względnego błędu F_0 .

CMOS

Definicja: Comparative Mean Opinion Score.

Jak działa / dlaczego jest ważne: Porównawcza ocena dwóch próbek przez słuchaczy.

CMUdict

Definicja: Słownik wymowy angielskiej.

Jak działa / dlaczego jest ważne: Mapuje słowa na sekwencje ARPAbet.

Conformer

Definicja: Transformer z modułem konwolucyjnym.

Jak działa / dlaczego jest ważne: Łączy globalny kontekst attention z lokalną ciągłością audio.

Duration

Definicja: Czas trwania zdarzenia.

Jak działa / dlaczego jest ważne: Steruje length regulatorem i synchronizacją fonemów z muzyką.

Embedding

Definicja: Uczona reprezentacja wektorowa tokenu.

Jak działa / dlaczego jest ważne: Koduje fonem, głos, styl i język w przestrzeni ciągłej.

Energy

Definicja: Miara siły sygnału.

Jak działa / dlaczego jest ważne: Steruje głośnością i obwiednią wykonania.

Exposure bias

Definicja: Różnica pomiędzy treningiem z referencją i inferencją z własnymi predykcjami.

Jak działa / dlaczego jest ważne: Może powodować kumulowanie błędów prosodii.

F_0

Definicja: Częstotliwość podstawowa.

Jak działa / dlaczego jest ważne: Określa postrzeganą wysokość głosu w ramach dźwięcznych.

Feature matching

Definicja: Porównanie aktywacji dyskryminatora dla realnego i generowanego audio.

Jak działa / dlaczego jest ważne: Stabilizuje trening wokodera GAN.

Fonem

Definicja: Jednostka dźwiękowa języka.

Jak działa / dlaczego jest ważne: Jest podstawową reprezentacją tekstu dla modelu SVS.

Formant

Definicja: Rezonans traktu głosowego.

Jak działa / dlaczego jest ważne: Kształtuje samogłoskę i barwę, ale nie jest tym samym co F_0 .

G2P

Definicja: Grapheme-to-phoneme.

Jak działa / dlaczego jest ważne: Zamienia zapis słowa na wymowę.

GAN

Definicja: Generative Adversarial Network.

Jak działa / dlaczego jest ważne: Generator i dyskryminator uczą się konkurencyjnie, poprawiając realizm waveformu.

HiFi-GAN

Definicja: Szybki neuronowy wokoder GAN.

Jak działa / dlaczego jest ważne: Wykorzystuje residualny generator oraz dyskryminatory wielookresowe i wieloskalowe.

Hop length

Definicja: Krok pomiędzy ramkami STFT.

Jak działa / dlaczego jest ważne: Określa rozdzielczość czasową mel-spektrogramu.

Length regulator

Definicja: Rozszerza zdarzenia do ramek.

Jak działa / dlaczego jest ważne: Powtarza reprezentację zgodnie z duration i umożliwia generację nieauto-regresyjną.

Log-mel

Definicja: Logarytmiczny mel-spektrogram.

Jak działa / dlaczego jest ważne: Kompresuje dynamikę i jest stabilnym celem modelu akustycznego.

MAE F_0

Definicja: Średni bezwzględny błąd wysokości.

Jak działa / dlaczego jest ważne: W pracy liczony w centach na ramkach voiced.

Mel-spektrogram

Definicja: Czasowo-częstotliwościowa reprezentacja na skali mel.

Jak działa / dlaczego jest ważne: Jest wyjściem modelu akustycznego i wejściem wokodera.

MOS

Definicja: Mean Opinion Score.

Jak działa / dlaczego jest ważne: Średnia subiektywna ocena słuchaczy, zwykle 1–5.

Multi-Period Discriminator

Definicja: Dyskryminator okresowości.

Jak działa / dlaczego jest ważne: Analizuje waveform dla kilku okresów, co pomaga w syntezie głosu.

Multi-Scale Discriminator

Definicja: Dyskryminator kilku skal czasowych.

Jak działa / dlaczego jest ważne: Oцени lokalny detal i szerszą strukturę sygnału.

Nyquist frequency

Definicja: Połowa sample rate.

Jak działa / dlaczego jest ważne: Wyznacza maksymalną częstotliwość bez aliasingu.

pYIN

Definicja: Probabilistyczny estymator F_0 .

Jak działa / dlaczego jest ważne: Śledzi pitch i voiced/unvoiced, ale może mieć błędy oktawowo.

Postnet

Definicja: Sieć poprawiająca bazowy mel.

Jak działa / dlaczego jest ważne: Przewiduje residualną korektę lokalnych struktur.

Prosodia

Definicja: Cechy wykonawcze ponad treścią fonemów.

Jak działa / dlaczego jest ważne: Obejmuje pitch, timing, energię, akcent, vibrato i frazowanie.

Sample rate

Definicja: Liczba próbek waveformu na sekundę.

Jak działa / dlaczego jest ważne: Wpływa na pasmo, koszt i rozdzielczość czasową.

Score F_0

Definicja: Wysokość wynikająca z partytury.

Jak działa / dlaczego jest ważne: Zapewnia kontrolę melodii i jest punktem odniesienia dla przewidywanej mikroprozodii.

Source-filter

Definicja: Model źródła i filtra głosu.

Jak działa / dlaczego jest ważne: Jawne harmoniczne źródło zależne od F_0 pomaga wokoderowi utrzymać pitch.

STFT

Definicja: Short-Time Fourier Transform.

Jak działa / dlaczego jest ważne: Tworzy reprezentację częstotliwości w kolejnych oknach czasu.

SVS

Definicja: Singing Voice Synthesis.

Jak działa / dlaczego jest ważne: Synteza śpiewu kontrolowanego tekstem, wysokością, rytmem i stylem.

Teacher forcing

Definicja: Podawanie referencyjnej wartości jako warunku podczas treningu.

Jak działa / dlaczego jest ważne: Stabilizuje uczenie, ale w nadmiarze powoduje exposure bias.

Vibrato

Definicja: Okresowa modulacja wysokości.

Jak działa / dlaczego jest ważne: Zwiększa naturalność, jeżeli ma odpowiednią szybkość i głębokość.

Voiced/unvoiced

Definicja: Rozróżnienie ramek okresowych i nieokresowych.

Jak działa / dlaczego jest ważne: Warunkuje obecność F_0 oraz harmonicznego źródła.

Vocoder

Definicja: Model rekonstruujący waveform.

Jak działa / dlaczego jest ważne: Przekształca mel-spektrogram, pitch i energię w audio.

Waveform

Definicja: Przebieg amplitudy w czasie.

Jak działa / dlaczego jest ważne: Jest ostatecznym sygnałem audio i podstawą odsłuchu.

11. Ostatnia lista kontrolna

Przed obroną należy umieć bez notatek:

1. opowiedzieć cały pipeline w 90 sekund;
2. podać wkład każdego autora;
3. wyjaśnić rolę Score IR;
4. podać najważniejsze wyniki lokalizacji, OCR, OMR i SVS;
5. wyjaśnić ograniczenia metodologiczne OMR;

6. powiedzieć, dlaczego 8,87 centa nie oznacza naturalnego wokułu;
7. narysować U-Net, CRNN, Faster R-CNN i tor model akustyczny–wokoder;
8. wyjaśnić CTC, IoU, AP, mAP, mel-spektrogram i F_0 ;
9. porównać zastosowane metody z co najmniej jedną alternatywą;
10. zaproponować trzy konkretne dalsze eksperymenty.