

# Przygotowanie do obrony pracy magisterskiej

Synteza piosenki z nut i tekstu z wykorzystaniem agenta AI

Szczegółowa mapa wiedzy, ograniczeń, alternatyw i potencjalnych pytań komisji

**Michał Bober:** lokalizacja tekstu, OCR, OMR, przetwarzanie dokumentów i integracja obrazu

**Igor Staręga:** Score IR, interpretacja muzyczna, synchronizacja tekstu i SVS

Materiał opracowano na podstawie finalnego pliku PDF pracy, zawartości repozytorium `svs_omr`, konfiguracji eksperymentalnych, kodu modeli, zestawu golden set oraz opinii promotora. Dokument jest przewodnikiem do nauki i próbnej obrony, a nie zastępstwem przeczytania własnej pracy.

Warszawa, 2026

## Spis treści

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Jak korzystać z dokumentu</b>                                  | <b>5</b>  |
| 1.1      | Priorytety nauki . . . . .                                        | 5         |
| <b>2</b> | <b>Źródła i ważne rozbieżności wersji</b>                         | <b>5</b>  |
| 2.1      | Widoczne ślady redakcyjne w przekazanym PDF-ie . . . . .          | 5         |
| <b>3</b> | <b>Co opinia promotora podpowiada o pytaniach komisji</b>         | <b>6</b>  |
| 3.1      | Interdyscyplinarność i przejście między reprezentacjami . . . . . | 6         |
| 3.2      | Score IR jako mocny wkład pracy . . . . .                         | 6         |
| 3.3      | Część OMR jako najmocniejsza eksperymentalnie . . . . .           | 7         |
| 3.4      | SVS: ograniczona skala i brak pełnego testu słuchowego . . . . .  | 7         |
| 3.5      | Prototyp badawczo-inżynierski a narzędzie użytkowe . . . . .      | 7         |
| 3.6      | Szeroki zakres kosztem nierównej głębokości modułów . . . . .     | 7         |
| 3.7      | Literatura jako uzasadnienie wyborów . . . . .                    | 7         |
| 3.8      | Osobisty wkład Michała i Igora . . . . .                          | 8         |
| <b>4</b> | <b>Zakres obowiązkowy dla obu autorów</b>                         | <b>8</b>  |
| 4.1      | Pełny przepływ systemu . . . . .                                  | 8         |
| 4.2      | Dlaczego podejście modułowe . . . . .                             | 8         |
| 4.3      | Co oznacza „agent AI” . . . . .                                   | 9         |
| 4.4      | Podstawowe pojęcia eksperymentalne . . . . .                      | 9         |
| 4.5      | Tezy pracy i ich ostrożna interpretacja . . . . .                 | 10        |
| <b>5</b> | <b>Michał Bober: lokalizacja tekstu</b>                           | <b>10</b> |
| 5.1      | Sformułowanie problemu . . . . .                                  | 10        |
| 5.2      | U-Net . . . . .                                                   | 10        |
| 5.3      | Attention U-Net . . . . .                                         | 10        |
| 5.4      | Pozostałe architektury . . . . .                                  | 11        |
| 5.5      | Funkcja straty i niezbalansowane klasy . . . . .                  | 11        |
| 5.6      | Metryki segmentacji . . . . .                                     | 11        |
| 5.7      | Postprocessing i wiedza dziedzinowa . . . . .                     | 12        |
| 5.8      | Wyniki lokalizacji tekstu . . . . .                               | 12        |
| 5.9      | Domain shift . . . . .                                            | 12        |
| 5.10     | Alternatywy lokalizacji tekstu . . . . .                          | 13        |
| 5.11     | Bank pytań: lokalizacja tekstu . . . . .                          | 13        |
| <b>6</b> | <b>Michał Bober: OCR</b>                                          | <b>13</b> |

|          |                                            |           |
|----------|--------------------------------------------|-----------|
| 6.1      | OCR jako rozpoznawanie sekwencji . . . . . | 13        |
| 6.2      | CRNN i ResNet-CRNN . . . . .               | 14        |
| 6.3      | Residual connections . . . . .             | 14        |
| 6.4      | Transformer OCR . . . . .                  | 14        |
| 6.5      | CTC . . . . .                              | 15        |
| 6.6      | Greedy decoding i beam search . . . . .    | 15        |
| 6.7      | Charset i znaczenie znaków . . . . .       | 15        |
| 6.8      | Metryki OCR . . . . .                      | 16        |
| 6.9      | Wyniki własnych modeli OCR . . . . .       | 16        |
| 6.10     | Zewnętrzne silniki . . . . .               | 16        |
| 6.11     | Alternatywy OCR . . . . .                  | 16        |
| 6.12     | Bank pytań: OCR . . . . .                  | 17        |
| <b>7</b> | <b>Michał Bober: OMR</b>                   | <b>17</b> |
| 7.1      | OMR a OCR . . . . .                        | 17        |
| 7.2      | DeepScoresV2 . . . . .                     | 18        |
| 7.3      | Faster R-CNN . . . . .                     | 18        |
| 7.3.1    | Region Proposal Network . . . . .          | 18        |
| 7.3.2    | Drugi etap . . . . .                       | 18        |
| 7.4      | Własny backbone . . . . .                  | 19        |
| 7.5      | Anchors i mikro-kotwice . . . . .          | 19        |
| 7.6      | Stride 8 i 16 . . . . .                    | 19        |
| 7.6.1    | Wyniki stride'u . . . . .                  | 20        |
| 7.7      | Kafelkowanie stron . . . . .               | 20        |
| 7.8      | Overlap . . . . .                          | 21        |
| 7.9      | Wyniki geometrii kafli . . . . .           | 21        |
| 7.10     | NMS . . . . .                              | 21        |
| 7.11     | Oriented bounding boxes . . . . .          | 21        |
| 7.12     | Metryki detekcyjne . . . . .               | 22        |
| 7.13     | Augmentacje . . . . .                      | 22        |
| 7.13.1   | Wyniki augmentacji . . . . .               | 23        |
| 7.14     | Najtrudniejsze klasy . . . . .             | 23        |
| 7.15     | Ograniczenia metodologiczne OMR . . . . .  | 24        |
| 7.15.1   | Pojedynczy seed . . . . .                  | 24        |
| 7.15.2   | Wybór checkpointu na teście . . . . .      | 24        |
| 7.15.3   | Różny budżet kroków . . . . .              | 24        |
| 7.16     | Alternatywy OMR . . . . .                  | 24        |

|          |                                                        |           |
|----------|--------------------------------------------------------|-----------|
| 7.17     | Bank pytań: OMR . . . . .                              | 25        |
| <b>8</b> | <b>Igor Staręga: Score IR i interpretacja muzyczna</b> | <b>25</b> |
| 8.1      | Rola Score IR . . . . .                                | 25        |
| 8.2      | Rekonstrukcja wysokości . . . . .                      | 25        |
| 8.3      | Rekonstrukcja rytmu . . . . .                          | 26        |
| 8.4      | Metrum i naprawa taktów . . . . .                      | 26        |
| 8.5      | Tie, slur i melisma . . . . .                          | 27        |
| 8.6      | Dopasowanie tekstu do nut . . . . .                    | 27        |
| 8.7      | Alternatywy interpretacji . . . . .                    | 27        |
| <b>9</b> | <b>Igor Staręga: Singing Voice Synthesis</b>           | <b>27</b> |
| 9.1      | SVS a TTS . . . . .                                    | 27        |
| 9.2      | Dane GTSinger . . . . .                                | 28        |
| 9.3      | Fonemy i G2P . . . . .                                 | 28        |
| 9.4      | Alokacja czasu fonemów . . . . .                       | 28        |
| 9.5      | Reprezentacja audio . . . . .                          | 29        |
| 9.5.1    | Próbkowanie . . . . .                                  | 29        |
| 9.5.2    | STFT . . . . .                                         | 29        |
| 9.5.3    | Mel-spektrogram . . . . .                              | 29        |
| 9.6      | $F_0$ , MIDI i centy . . . . .                         | 29        |
| 9.7      | Architektura modelu akustycznego . . . . .             | 30        |
| 9.8      | Transformer event encoder . . . . .                    | 30        |
| 9.9      | Length regulator . . . . .                             | 30        |
| 9.10     | Conformer . . . . .                                    | 31        |
| 9.11     | Score-relative $F_0$ . . . . .                         | 31        |
| 9.12     | Prosody feedback i teacher forcing . . . . .           | 31        |
| 9.13     | Postnet, detail projection i mel refiner . . . . .     | 31        |
| 9.14     | Straty modelu akustycznego . . . . .                   | 32        |
| 9.15     | Wokoder inspirowany HiFi-GAN . . . . .                 | 32        |
| 9.16     | GAN i feature matching . . . . .                       | 32        |
| 9.17     | Source-filter . . . . .                                | 33        |
| 9.18     | Pitch-shift sensitivity . . . . .                      | 33        |
| 9.19     | Niedopasowanie model akustyczny–wokoder . . . . .      | 33        |
| 9.20     | Audio-proxy . . . . .                                  | 33        |
| 9.21     | Wyniki finalnego SVS . . . . .                         | 34        |
| 9.22     | Clean i humanized . . . . .                            | 34        |
| 9.23     | Transpozycja . . . . .                                 | 34        |

|           |                                                             |           |
|-----------|-------------------------------------------------------------|-----------|
| 9.24      | Ograniczenia ewaluacji SVS . . . . .                        | 34        |
| 9.25      | Jak zaprojektować test percepcyjny . . . . .                | 35        |
| 9.26      | Alternatywy SVS . . . . .                                   | 35        |
| <b>10</b> | <b>Najważniejsze ograniczenia całej pracy</b>               | <b>35</b> |
| <b>11</b> | <b>Pytania wspólne i metodologiczne</b>                     | <b>36</b> |
| <b>12</b> | <b>Najbardziej niebezpieczne pytania komisji</b>            | <b>37</b> |
| <b>13</b> | <b>Liczby, które warto znać z pamięci</b>                   | <b>38</b> |
| 13.1      | Lokalizacja tekstu . . . . .                                | 38        |
| 13.2      | OCR . . . . .                                               | 38        |
| 13.3      | OMR . . . . .                                               | 38        |
| 13.4      | SVS . . . . .                                               | 39        |
| <b>14</b> | <b>Szybki bank dodatkowych pytań bez pełnych odpowiedzi</b> | <b>39</b> |
| 14.1      | Pytania do Michała . . . . .                                | 39        |
| 14.2      | Pytania do Igora . . . . .                                  | 40        |
| <b>15</b> | <b>Plan nauki przed obroną</b>                              | <b>40</b> |
| 15.1      | Etap 1: wspólna narracja . . . . .                          | 40        |
| 15.2      | Etap 2: własny zakres . . . . .                             | 41        |
| 15.3      | Etap 3: wzajemne odpytywanie . . . . .                      | 41        |
| 15.4      | Etap 4: próbna komisja . . . . .                            | 41        |
| <b>16</b> | <b>Przykładowa próbna obrona</b>                            | <b>41</b> |
| 16.1      | Zestaw dla Michała . . . . .                                | 41        |
| 16.2      | Zestaw dla Igora . . . . .                                  | 42        |
| <b>17</b> | <b>Ostatnia checklista przed obroną</b>                     | <b>42</b> |
| <b>18</b> | <b>Podsumowanie</b>                                         | <b>42</b> |

## 1. Jak korzystać z dokumentu

Materiał został ułożony tak, aby najpierw zabezpieczyć pytania wspólne, następnie zakres każdego autora, a na końcu pytania krytyczne, liczby i scenariusze próbnej obrony. Najważniejszym celem nie jest pamięciowe odtworzenie wszystkich parametrów, lecz umiejętność:

1. zdefiniowania pojęcia,
2. wyjaśnienia jego roli w pracy,
3. uzasadnienia dokonanego wyboru,
4. uczciwego wskazania ograniczenia,
5. zaproponowania rozsądnej alternatywy lub dalszego eksperymentu.

Najbezpieczniejszy schemat odpowiedzi na obronie:

**Definicja → zastosowanie w pracy → uzasadnienie → wynik → ograniczenie → możliwe ulepszenie.**

Nie należy przedstawiać pracy jako systemu pozbawionego ograniczeń. Komisja zwykle lepiej ocenia świadomą krytykę metodologii niż próbę obrony każdej decyzji jako jedynej możliwej.

### 1.1. Priorytety nauki

**Priorytet A – obowiązkowy.** Cały pipeline, tezy pracy, wkład autorów, podstawowe metryki, najważniejsze wyniki, ograniczenia metodologiczne i odpowiedzi wynikające z opinii promotora.

**Priorytet B – własny zakres.** Michał: segmentacja tekstu, CTC OCR, Faster R-CNN, DeepScoresV2, kafelkowanie, augmentacje i metryki detekcyjne. Igor: Score IR, melodia, rytm, fonemizacja, model akustyczny, Conformer, F0, mel-spektrogram i wokoder.

**Priorytet C – alternatywy.** Umiejętność porównania zastosowanych metod z rozwiązaniami takimi jak DBNet, TrOCR, FCOS, YOLO, DETR, Mask R-CNN, DiffSinger, FastSpeech, WORLD, NSF-HiFiGAN czy podejście end-to-end.

**Priorytet D – szczegóły.** Konkretnie hiperparametry i mniej centralne elementy kodu. Są przydatne, lecz komisja prawdopodobnie będzie bardziej zainteresowana znaczeniem decyzji niż nazwą pojedynczej funkcji.

## 2. Źródła i ważne rozbieżności wersji

Źródłem nadrzędnym dla liczb i sformułowanych wniosków jest finalny przesłany PDF pracy liczący 83 strony. Repozytorium wykorzystano do potwierdzenia architektur, konfiguracji, przepływu danych i szczegółów niewyjaśnionych szeroko w tekście.

**W finalnym PDF-ie użyto dziesięcioelementowego golden setu.** Średni błąd  $F_0$  wariantu clean wynosi 8,87 centa, a wariantu humanized 9,69 centa. W roboczym źródle pracy pozostawały wcześniejsze wartości dla pięciu próbek. Na obronie i w prezentacji należy konsekwentnie używać danych z finalnego PDF-u.

### 2.1. Widoczne ślady redakcyjne w przekazanym PDF-ie

W przesłanej wersji PDF widoczne są:

- na stronie 5, w angielskim streszczeniu, fragment degradations. Wykonaj In particular;
- na stronie 60, w podpisie tabeli 5.4, komentarz [Czy wyeksportować do appendix i odnieść się w taki sposób?].

Jeżeli dokument nie został jeszcze ostatecznie zdeponowany, elementy te należy poprawić. Jeżeli wersja została już złożona, warto być świadomym problemu i nie dać się nim zaskoczyć.

### 3. Co opinia promotora podpowiada o pytaniach komisji

Opinia promotora jest ważna, ponieważ pozostali członkowie komisji mogą zobaczyć w niej gotowe obszary do pogłębienia. Recenzja jest bardzo pozytywna, ale równocześnie wskazuje kilka miejsc, w których komisja może sprawdzić dojrzałość autorów.

#### 3.1. Interdyscyplinarność i przejście między reprezentacjami

Promotor podkreśla, że problem łączy:

- przetwarzanie obrazów dokumentów,
- OCR,
- optyczne rozpoznawanie muzyki,
- symboliczną reprezentację zapisu nutowego,
- fonemizację,
- neuronową syntezę wokalu.

Możliwe pytanie komisji nie musi dotyczyć pojedynczego modelu. Może brzmieć: „Gdzie znajduje się najtrudniejsze przejście między tymi dziedzinami?”.

#### Pytanie: Gdzie w systemie znajduje się najważniejsza luka reprezentacyjna?

**Odpowiedź wzorcowa:** Obraz partytury jest strukturą dwuwymiarową i relacyjną, natomiast SVS oczekuje uporządkowanej osi czasu: fonemów, wysokości, czasów trwania, pauz i cech prozodycznych. Najważniejszym zadaniem nie jest więc sama detekcja obiektów, lecz przejście od geometrii strony do semantyki muzycznej i sekwencji czasowej. Rolę pomostu pełni Score IR.

#### 3.2. Score IR jako mocny wkład pracy

W opinii Score IR został wskazany jako szczególnie wartościowe rozwiązanie. Komisja może oczekiwać nie tylko definicji, ale odpowiedzi, dlaczego zwykły JSON z nutami lub bezpośredni CSV dla SVS nie wystarczył.

#### Pytanie: Dlaczego Score IR jest czymś więcej niż formatem technicznym?

**Odpowiedź wzorcowa:** Score IR pełni jednocześnie rolę kontraktu między modułami i narzędzia badawczego. Zachowuje surowe źródła, confidence, symbole, relacje, ostrzeżenia i naprawy, dzięki czemu można odróżnić błąd percepcji obrazu od błędu interpretacji muzycznej. Minimalny CSV dla SVS usuwałby większość tej informacji i utrudniał diagnozę.

### 3.3. Część OMR jako najmocniejsza eksperymentalnie

Promotor wyraźnie ocenia część OMR jako mocniejszą i lepiej udokumentowaną od SVS. Może to prowadzić do pytań:

- dlaczego właśnie te eksperymenty OMR uznano za najważniejsze;
- czy porównania były uczciwe;
- jaki jest związek metryk detekcyjnych z końcową rekonstrukcją muzyki;
- dlaczego nie wszystkie klasy reagowały jednakowo na kafelkowanie;
- jakie są ograniczenia pojedynczego seedu i wyboru checkpointu na zbiorze testowym.

### 3.4. SVS: ograniczona skala i brak pełnego testu słuchowego

Recenzja wprost wskazuje brak szerokiej oceny z udziałem słuchaczy. Jest to prawdopodobny temat pytania dla Igora.

**Pytanie: Dlaczego ewaluacja SVS nie pozwala jeszcze mówić o jakości użytkowej?**

**Odpowiedź wzorcowa:** Golden set ma tylko dziesięć próbek, a główna metryka ocenia zgodność  $F_0$ , nie pełną naturalność. Nie wykonano szerokiego testu MOS lub CMOS z grupą słuchaczy, nie rozdzielono systematycznie ocen naturalności, zrozumiałości tekstu, barwy, podobieństwa głosu i jakości frazowania. Wynik dowodzi działania i kontroli melodii w prototypie, ale nie równoważności z gotowym produktem.

### 3.5. Prototyp badawczo-inżynierski a narzędzie użytkowe

Promotor zaznacza, że stwierdzenie „system umożliwia syntezę piosenki” jest prawdziwe w sensie prototypu, ale nie oznacza jakości porównywalnej z gotowymi narzędziami.

**Pytanie: Czy zrealizowany system jest produktem?**

**Odpowiedź wzorcowa:** Nie. Jest kompletnym prototypem badawczo-inżynierskim: działa od obrazu lub PDF-u do artefaktów muzycznych i audio, pozwala trenować, porównywać i diagnozować moduły. Produkt wymagałby znacznie większej odporności domenowej, stabilności, ergonomicznej korekty błędów, testów użytkowników, kontroli jakości, wydajności oraz szerszej ewaluacji percepcyjnej.

### 3.6. Szeroki zakres kosztem nierównej głębokości modułów

Komisja może zapytać, czy zakres nie był zbyt szeroki.

**Pytanie: Czy lepiej byłoby ograniczyć pracę do jednego modułu?**

**Odpowiedź wzorcowa:** Węższa praca pozwoliłaby pogłębić jeden komponent i wykonać więcej powtórzeń eksperymentów. Jednak celem tej pracy było zbadanie pełnego przejścia od obrazu do śpiewu i obserwowalności modułowego systemu. Szeroki zakres był więc zgodny z celem, choć jego ceną jest nierówna dojrzałość modułów, zwłaszcza ograniczona ewaluacja SVS.

### 3.7. Literatura jako uzasadnienie wyborów

Promotor wymienia konkretne rodziny metod: DeepScoresV2, Faster R-CNN, U-Net, Attention U-Net, DeepLabV3+, CRNN, TrOCR, PaddleOCR, Transformer, Tacotron, FastSpeech, DiffSinger i HiFi-GAN.

Nie trzeba znać wszystkich publikacji strona po stronie, ale trzeba umieć powiedzieć:



- jaki problem rozwiązuje dana metoda;
- dlaczego została użyta lub potraktowana jako alternatywa;
- czym różni się od metody o podobnym przeznaczeniu;
- jakie ma założenia i ograniczenia.

### 3.8. Osobisty wkład Michała i Igora

Każdy autor powinien umieć jasno wyjaśnić:

- co zaprojektował i zaimplementował samodzielnie;
- jakie eksperymenty prowadził;
- jakie decyzje podejmował wspólnie;
- które ograniczenia własnej części uważa za najważniejsze;
- jak jego moduł wpływa na pracę drugiego autora.

#### Pytanie: Jaki był wkład Michała Bobera?

**Odpowiedź wzorcowa:** Przetwarzanie obrazu i tekstu: lokalizacja tekstu, OCR, OMR, przygotowanie Deep-ScoresV2, konfiguracja i eksperymenty Faster R-CNN, obrazy i PDF-y, kafelkowanie, augmentacje, ewaluacja detekcji oraz integracja wyników obrazu w aplikacji.

#### Pytanie: Jaki był wkład Igora Staręgi?

**Odpowiedź wzorcowa:** Interpretacja muzyczna, Score IR, przejście od symboli do melodii i rytmu, synchronizacja tekstu z nutami, przygotowanie formatu dla SVS, model akustyczny, wokoder, ewaluacja muzyczna i wokalna oraz diagnostyka toru syntezy.

## 4. Zakres obowiązkowy dla obu autorów

### 4.1. Pełny przepływ systemu

**obraz/PDF** → rasteryzacja i preprocessing → lokalizacja tekstu → OCR → OMR → Score IR →  
MusicXML/MIDI/CSV → model akustyczny SVS → wokoder → audio

Ścieżka tekstowa i muzyczna działają początkowo równolegle. Lokalizacja tekstu wyznacza regiony dla OCR i może służyć do zamaskowania tekstu przed OMR. Detektor OMR zwraca symbole muzyczne, ale nie uporządkowaną muzykę. Obie ścieżki są łączone przez Score IR.

### 4.2. Dlaczego podejście modułowe

**Zalety:**

- każdy moduł ma osobne dane i właściwe metryki;
- modele można trenować i wymieniać niezależnie;
- łatwiej wskazać źródło błędu;
- można stosować oracle i testować dalszy tor bez błędów wcześniejszych etapów;

- melodia, rytm i tekst pozostają jawnie kontrolowane;
- artefakty pośrednie można wizualizować i ręcznie poprawiać.

**Wady:**

- błędy propagują się między modułami;
- każdy interfejs może utracić część informacji;
- lokalnie najlepszy model nie musi dawać najlepszego wyniku końcowego;
- moduły nie są optymalizowane wspólnie;
- heurystyki mogą być kruche przy zmianie domeny;
- integracja wielu środowisk i checkpointów zwiększa złożoność.

**Pytanie: Dlaczego nie zastosowano jednego modelu end-to-end?**

**Odpowiedź wzorcowa:** Wymagałby dużego zbioru par obraz partytury–docelowy wokal oraz nauczania w jednym modelu percepcji dokumentu, semantyki muzycznej, wymowy i generacji audio. Taki zbiór jest trudny do pozyskania, a model byłby słabo obserwowalny. Podejście modułowe lepiej odpowiadało dostępnym danym i celowi badawczemu.

### 4.3. Co oznacza „agent AI”

Pojęcie nie oznacza jednego autonomicznego LLM. Oznacza współpracę wyspecjalizowanych modułów AI pod kontrolą deterministycznej orkiestracji. Moduł lokalizacji, OCR, OMR i SVS otrzymuje wejście, wykonuje wyspecjalizowane zadanie i przekazuje jawny wynik dalej.

**Pułapka:** Nie należy twierdzić, że system samodzielnie planuje cele, korzysta z narzędzi jak agent LLM albo autonomicznie poprawia swoje modele. Warstwa sterująca uruchamia z góry zdefiniowany pipeline i reguły walidacyjne.

### 4.4. Podstawowe pojęcia eksperymentalne

**Train set** Dane używane do aktualizacji wag modelu.

**Validation set** Dane używane do wyboru hiperparametrów, checkpointu i early stopping.

**Test set** Dane przeznaczone wyłącznie do końcowej, możliwie bezstronnej oceny.

**Ground truth** Referencyjna, uznana za prawdziwą adnotacja.

**Checkpoint** Zapis wag modelu, a często także optymalizatora, epoki i konfiguracji.

**Overfitting** Dopasowanie do danych treningowych kosztem generalizacji.

**Domain shift** Różnica rozkładu między danymi treningowymi i docelowymi.

**Augmentacja** Losowa transformacja próbki, która ma zachować jej etykietę i poszerzyć rozkład treningowy.

**Ablation study** Kontrolowany eksperyment usuwający lub zmieniający jeden składnik, aby zbadać jego wpływ.

**Oracle** Ręcznie poprawione wejście dalszego modułu, używane do odseparowania błędów wcześniejszego pipeline’u.

**Golden set** Mały, stabilny i ręcznie kontrolowany zestaw regresyjny oraz diagnostyczny.

## 4.5. Tezy pracy i ich ostrożna interpretacja

- T1 – obserwowalność.** Częściowo potwierdzona. Artefakty pozwalają rozróżniać błędy, ale obserwowalność oceniono głównie jakościowo.
- T2 – stride.** Częściowo potwierdzona. Stride 8 poprawił mAP na teście bazowym, lecz na degradowanym wyniki zagregowane były zbliżone, a zmienił się kompromis precision–recall.
- T3 – kafelkowanie.** Potwierdzona z ograniczeniem. Kafle 768 były najlepsze, ale konfiguracje miały różną liczbę kroków treningowych.
- T4 – augmentacje.** Potwierdzona w badanym zakresie. Poprawiły odporność na kontrolowane degradacje, ale nie dowodzą odporności na prawdziwe zdjęcia.
- T5 – diagnostyka SVS.** Częściowo potwierdzona. Audio-proxy, oracle i ablacja  $F_0$  pomogły znaleźć problemy, lecz golden set jest mały i nie wykonano pełnej oceny słuchowej.

## 5. Michał Bober: lokalizacja tekstu

### 5.1. Sformułowanie problemu

Lokalizację tekstu potraktowano jako binarną segmentację semantyczną. Dla każdego piksela model przewidyje prawdopodobieństwo przynależności do tekstu. Po progowaniu powstaje maska, z której przez analizę konturów, morfologię i grupowanie wyznaczane są regiony oraz cropy dla OCR.

#### Pytanie: Dlaczego segmentacja zamiast samych bounding boxów?

**Odpowiedź wzorcowa:** Tekst wokalny składa się z cienkich i nieregularnych struktur. Maska lepiej odwzorowuje kształt niż prostokąt, ogranicza ilość tła w cropie i może służyć do maskowania tekstu przed OMR. Bounding box jest prostszy, ale obejmuje puste przestrzenie, pięciolinie i symbole.

### 5.2. U-Net

U-Net ma symetryczną strukturę encoder–decoder:

- encoder zmniejsza rozdzielczość i uczy coraz bardziej abstrakcyjnych cech;
- bottleneck przechowuje reprezentację o największym polu recepcyjnym;
- decoder zwiększa rozdzielczość;
- skip connections przekazują szczegóły przestrzenne z encodera.

#### Pytanie: Po co skip connections?

**Odpowiedź wzorcowa:** Podczas downsamplingu mogą zniknąć cienkie kreski liter i dokładne położenie granic. Skip connections dostarczają decoderowi cechy o wyższej rozdzielczości, dzięki czemu może odtworzyć drobne elementy maski.

### 5.3. Attention U-Net

Attention gate otrzymuje cechy skip connection oraz sygnał z decodera. Obie reprezentacje są rzutowane do wspólnego wymiaru, sumowane, przepuszczane przez aktywację i sigmoid. Powstała mapa wag mnoży cechy encodera.

**Pytanie: Co rzeczywiście robi attention gate?**

**Odpowiedź wzorcowa:** Uczy się przestrzennie wzmacniać cechy istotne dla segmentowanego tekstu i tłumić tło. Nie „czyta” tekstu i nie jest modelem językowym. Jest mechanizmem selekcji cech.

**5.4. Pozostałe architektury**

**U-Net++** Zagnieżdżone i gęstsze skip connections zmniejszające lukę semantyczną między encoderem i decoderem.

**DeepLabV3+** Atrous convolution i decoder granic; szeroki kontekst bez równie silnej utraty rozdzielczości.

**FPN** Piramida cech na wielu skalach.

**ResNet-34** Residual connections ułatwiające uczenie głębszego encodera.

W eksperymentach encodery ResNet-34 nie korzystały z wag ImageNet (`encoder_weights=None`). Brak transfer learningu może częściowo tłumaczyć brak jednoznacznej przewagi bardziej złożonych architektur.

**5.5. Funkcja straty i niebalansowane klasy**

Wykorzystano:

$$\mathcal{L} = \mathcal{L}_{\text{BCEWithLogits}} + \mathcal{L}_{\text{Dice}}.$$

`BCEWithLogitsLoss` łączy stabilną numerycznie funkcję sigmoid z binary cross-entropy. Parametr `pos_weight=5` zwiększa koszt błędu dla rzadkiej klasy tekstowej.

Dice Loss:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i p_i y_i + \epsilon}{\sum_i p_i + \sum_i y_i + \epsilon}.$$

**Pytanie: Dlaczego nie użyć zwykłego accuracy?**

**Odpowiedź wzorcowa:** Większość strony jest tłem. Model przewidujący wszędzie tło mógłby osiągnąć wysokie accuracy, ale nie znaleźć żadnego tekstu. Precision, recall, F1, IoU i Dice lepiej oceniają klasę mniejszościową.

**5.6. Metryki segmentacji**

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN},$$

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}},$$

$$\text{IoU} = \frac{TP}{TP + FP + FN}, \quad \text{Dice} = \frac{2TP}{2TP + FP + FN}.$$

Przy takim samym sposobie agregacji Dice jest równoważny pikselowemu F1.

## 5.7. Postprocessing i wiedza dziedzinowa

Repozytorium wykorzystuje:

- binaryzację i morfologiczne wykrywanie poziomych linii;
- grupowanie pięciu linii w pięciolinie;
- szacowanie odstępu między liniami;
- rekonstrukcję brakującej linii;
- wyznaczanie stref tekstu poniżej pięciolinii;
- opcjonalne usuwanie linii pięciolinii przed segmentacją;
- próg maski, domyślnie około 0,3;
- operację closing i dylatację;
- analizę konturów i minimalnego pola;
- grupowanie fragmentów w wiersze;
- filtrowanie nagłówków i regionów zawierających wyłącznie cyfry.

**Pytanie: Czy jest to system czysto neuronowy?**

**Odpowiedź wzorcowa:** Nie. Predykcja maski jest neuronowa, ale jej wykorzystanie jest wspierane heurystykami opartymi na geometrii pięciolinii i typowym położeniu tekstu wokálního. Jest to system hybrydowy.

**Pułapka:** Heurystyka „tekst znajduje się pod pięciolinia” nie jest uniwersalna. Może zawieść dla wielu zwrotek, nietypowego układu, tekstu pomiędzy głosami, partytur chóralnych i opisów umieszczonych w podobnej strefie.

## 5.8. Wyniki lokalizacji tekstu

| Model                | Precision | Recall | F1           | IoU          |
|----------------------|-----------|--------|--------------|--------------|
| U-Net                | 0,843     | 0,979  | 0,906        | 0,828        |
| Attention U-Net      | 0,849     | 0,977  | <b>0,909</b> | <b>0,832</b> |
| U-Net++ ResNet-34    | 0,833     | 0,980  | 0,901        | 0,820        |
| DeepLabV3+ ResNet-34 | 0,816     | 0,979  | 0,890        | 0,802        |
| FPN ResNet-34        | 0,806     | 0,984  | 0,886        | 0,796        |

**Do zapamiętania:** Attention U-Net uzyskał najlepszy wynik, ale przewaga nad U-Net wynosi tylko 0,003 F1. Należy mówić o niewielkiej przewadze w konkretnym eksperymencie, a nie o uniwersalnej dominacji architektury.

## 5.9. Domain shift

Dane dokumentowe zawierały faktury, formularze i dokumenty ogólne, a nie partytury. Model może więc:

- mylić pięciolinie, belki i laseczki z fragmentami liter;
- nie znać czcionek i rozstawu tekstu typowych dla wydawnictw muzycznych;
- dobrze wypadać na teście dokumentowym, ale gorzej w domenie docelowej.

**Pytanie: Jak poprawić generalizację lokalizacji tekstu?**

**Odpowiedź wzorcowa:** Przygotować anotowany zbiór partytur wokalnych, generować syntetyczne partytury z maskami, zastosować fine-tuning lub domain adaptation, użyć pretrenowanego encodera, dodać bardziej realistyczne degradacje i mierzyć wynik bezpośrednio na pełnych stronach nutowych.

**5.10. Alternatywy lokalizacji tekstu**

- DBNet, CRAFT i EAST jako detektory tekstu;
- Mask R-CNN jako detekcja z maską instancji;
- SegFormer i inne segmentery transformerowe;
- multi-task learning: tekst, pięciolinie i regiony muzyczne;
- czysto geometryczny baseline oparty na pięcioliniach;
- wspólny model lokalizacji i OCR;
- pretraining na dokumentach i fine-tuning na partyturach.

**5.11. Bank pytań: lokalizacja tekstu****Pytanie: Jaka jest różnica między segmentacją semantyczną i instancyjną?**

**Odpowiedź wzorcowa:** Segmentacja semantyczna przypisuje klasę każdemu pikselowi, ale nie rozdziela osobnych obiektów tej samej klasy. Segmentacja instancyjna dodatkowo identyfikuje oddzielne wystąpienia, np. osobne słowa lub wiersze.

**Pytanie: Co się stanie przy zbyt niskim progu maski?**

**Odpowiedź wzorcowa:** Wzrośnie recall, ale pojawi się więcej fałszywych pikseli i regionów, które mogą zawierać symbole muzyczne. Zbyt wysoki próg zwiększy precision kosztem przerwanych lub pominiętych liter.

**Pytanie: Czy wysoki recall zawsze jest pożądany?**

**Odpowiedź wzorcowa:** Nie. Jeżeli uzyskano go przez oznaczenie dużej części tła jako tekstu, OCR dostanie zaszumione cropy, a maskowanie przed OMR może usunąć symbole muzyczne.

**Pytanie: Dlaczego usuwanie pięciolinii może być ryzykowne?**

**Odpowiedź wzorcowa:** Operacja może usunąć fragmenty liter przecinające się z wykrytymi liniami albo uszkodzić znaki, jeśli geometria pięciolinii została oszacowana błędnie.

**Pytanie: Jak ocenić cały moduł, a nie sam segmenter?**

**Odpowiedź wzorcowa:** Należy mierzyć nie tylko IoU maski, ale także wykrycie kompletnych wierszy, kompletność cropów, kolejność odczytu i wpływ na CER, sylabizację oraz końcowe dopasowanie tekstu do nut.

**6. Michał Bober: OCR****6.1. OCR jako rozpoznawanie sekwencji**

Wejściem własnego OCR jest crop tekstu. Obraz:

1. jest skalowany do wysokości 32 pikseli;
2. zachowuje proporcje;
3. jest dopełniany białym tłem do szerokości 512 pikseli;
4. jest konwertowany do skali szarości i normalizowany;
5. przechodzi przez CNN;
6. wymiar poziomy mapy cech staje się sekwencją;
7. sekwencję modeluje BiLSTM albo Transformer;
8. CTC dekoduje wynik do znaków.

## 6.2. CRNN i ResNet-CRNN

CRNN łączy:

- CNN do ekstrakcji cech wizualnych;
- RNN/BiLSTM do modelowania zależności w sekwencji;
- liniową głowicę znakową;
- CTC do uczenia bez anotacji granic znaków.

**Pytanie: Dlaczego oś pozioma obrazu jest osią czasu?**

**Odpowiedź wzorcowa:** W tekstach poziomych kolejność znaków odpowiada przesuwaniu się od lewej do prawej. CNN kompresuje wysokość obrazu, pozostawiając kolejne kolumny cech jako uporządkowaną sekwencję obserwacji.

**Pytanie: Co daje BiLSTM?**

**Odpowiedź wzorcowa:** Każda pozycja korzysta zarówno z kontekstu po lewej, jak i po prawej. W OCR cały obraz jest dostępny, więc nie ma wymogu przetwarzania przyczynowego.

## 6.3. Residual connections

Blok residualny uczy funkcję:

$$y = F(x) + x,$$

ewentualnie z projekcją  $x$ , gdy zmienia się rozmiar lub liczba kanałów. Skrócona ścieżka ułatwia propagację gradientu i pozwala głębszej sieci uczyć się poprawek względem wejścia.

## 6.4. Transformer OCR

Wariant ResNet–Transformer–CTC zawiera:

- ResNet jako visual encoder;
- projekcję cech do wymiaru 256;
- sinusoidalne kodowanie pozycyjne;

- cztery warstwy Transformer Encoder;
- osiem głów attention;
- CTC jako wyjście.

### Pytanie: Dlaczego Transformer nie wygrał?

**Odpowiedź wzorcowa:** Większa złożoność nie gwarantuje poprawy. Model był trenowany od zera, zadanie miało stosunkowo krótkie sekwencje i silną lokalną strukturę, a dane oraz jakość cropów mogły być ważniejszym ograniczeniem niż pojemność modelu. BiLSTM ma korzystny inductive bias dla monotonicznego tekstu.

## 6.5. CTC

Connectionist Temporal Classification pozwala trenować model bez jawnego wskazywania, której kolumnie obrazu odpowiada konkretny znak. Wprowadza token blank i sumuje prawdopodobieństwa wszystkich monotonicznych ścieżek, które po redukcji dają tekst docelowy.

Redukcja ścieżki:

1. scala kolejne identyczne etykiety;
2. usuwa blanki.

Przykład:

\_ h h \_ e \_ l \_ l \_ o \_ → hello.

### Pytanie: Po co blank?

**Odpowiedź wzorcowa:** Pozwala reprezentować brak znaku i rozdzielić powtarzające się litery. Bez blanku sekwencja dwóch identycznych liter mogłaby zostać zredukowana do jednej.

### Pytanie: Jakie główne założenie ma CTC?

**Odpowiedź wzorcowa:** Kolejność etykiet jest monotoniczna względem sekwencji wejściowej. CTC nie jest odpowiednie do swobodnej zmiany kolejności znaków.

## 6.6. Greedy decoding i beam search

Repo stosuje greedy decoding: w każdym kroku wybiera najbardziej prawdopodobną klasę, a następnie redukuje ścieżkę CTC.

**Greedy** szybki, prosty, ale lokalnie optymalny.

**Beam search** utrzymuje kilka hipotez i może uwzględniać słownik lub model językowy; jest wolniejszy, ale może poprawić pełne napisy.

## 6.7. Charset i znaczenie znaków

Charset obejmuje litery, cyfry, spacje, interpunkcję i myślniki. W zwykłym OCR pojedynczy myślnik może być drobnym błędem. W partyturze wokalne może określać granicę sylaby i sposób przypisania słowa do kilku nut.



## 6.8. Metryki OCR

$$\text{CER} = \frac{S + D + I}{N},$$

gdzie  $S$  oznacza podstawienia,  $D$  usunięcia,  $I$  wstawienia, a  $N$  długość tekstu referencyjnego.

Exact match:

$$\text{ExactMatch} = \frac{N_{\text{identycznych predykcji}}}{N_{\text{wszystkich próbek}}}.$$

**Pytanie: Czy CER może być większy od 1?**

**Odpowiedź wzorcowa:** Tak. Jeżeli model generuje bardzo dużo dodatkowych znaków, liczba wstawień może przekroczyć długość referencji.

**Pytanie: Dlaczego exact match jest ważny dla tej pracy?**

**Odpowiedź wzorcowa:** Pojedynczy błąd w spacji, myślniku lub sylabie może zmienić późniejsze dopasowanie tekstu do nut, mimo że globalny CER pozostaje niski.

## 6.9. Wyniki własnych modeli OCR

| Model                        | Liczba próbek | CER           | Exact match   |
|------------------------------|---------------|---------------|---------------|
| CRNN                         | 16842         | 0,1382        | 0,5278        |
| ResNet-CRNN                  | 16842         | 0,1378        | 0,5255        |
| ResNet-CRNN hidden512        | 16842         | <b>0,1318</b> | <b>0,5366</b> |
| ResNet-Transformer-CTC small | 16842         | 0,1355        | 0,5321        |

**Do zapamiętania:** Najlepszy własny model to ResNet-CRNN hidden512, ale różnice między wariantami są niewielkie. Wniosek: samo zwiększenie pojemności nie rozwiązało problemu danych, cropów i przesunięcia domenowego.

## 6.10. Zewnętrzne silniki

**EasyOCR** Gotowy praktyczny pipeline OCR.

**PaddleOCR/PP-OCR** Lekki system detekcji, korekcji i rozpoznawania; domyślne praktyczne rozwiązanie aplikacji to PaddleOCR v5 mobile.

**TrOCR** Vision Transformer/encoder obrazu oraz autoregresyjny Transformer decoder.

**Pytanie: Czy użycie PaddleOCR w aplikacji podważa sens trenowania własnego OCR?**

**Odpowiedź wzorcowa:** Nie. Własne modele pozwoliły przeprowadzić kontrolowane badanie architektur i CTC, natomiast aplikacja została zaprojektowana modułowo i może korzystać z praktycznie najlepszego dostępnego backendu. Badanie naukowe i wybór produkcyjny nie muszą wskazywać tego samego modelu.

## 6.11. Alternatywy OCR

- beam search CTC z modelem językowym;

- fine-tuning TrOCR lub PaddleOCR na partyturach;
- encoder-decoder bez CTC;
- rozpoznawanie całego wiersza zamiast krótkich fragmentów;
- dopasowanie OCR do transkrypcji podanej przez użytkownika;
- słownikowe lub językowe poprawianie tekstu;
- wspólny model lokalizacji i rozpoznawania;
- metryki sylabizacji i zgodności liczby sylab z nutami.

## 6.12. Bank pytań: OCR

### Pytanie: Dlaczego zachowuje się proporcje obrazu?

**Odpowiedź wzorcowa:** Rozciągnięcie słowa zmienia geometrię znaków i odstępy. Skalowanie do stałej wysokości z dopełnieniem szerokości zachowuje kształt, a jednocześnie daje stały rozmiar tensora.

### Pytanie: Co oznacza CER równy 0,1318?

**Odpowiedź wzorcowa:** Średnia liczba operacji edycyjnych odpowiada około 13,18% liczby znaków referencyjnych. Nie oznacza to jednak, że dokładnie 13,18% znaków w każdej próbie jest błędne.

### Pytanie: Czy można mieć niski CER i bezużyteczny wynik dla SVS?

**Odpowiedź wzorcowa:** Tak. Błędy mogą koncentrować się w myślnikach, spacjach i granicach sylab, które mają większy wpływ muzyczny niż przypadkowa literówka.

### Pytanie: Jak uczciwie ocenić sam OCR?

**Odpowiedź wzorcowa:** Na referencyjnych cropach, aby wyłączyć błędy lokalizacji. Osobno należy ocenić pełny tor lokalizacja+OCR na całych stronach.

### Pytanie: Dlaczego WER nie był główną metryką?

**Odpowiedź wzorcowa:** Próbkę są często krótkie i zawierają fragmenty lub sylaby. CER daje bardziej szczegółową informację znakową. WER byłby wartościową metryką dodatkową dla pełnych wierszy tekstu.

## 7. Michał Bober: OMR

### 7.1. OMR a OCR

OCR zazwyczaj odtwarza liniową sekwencję znaków. OMR analizuje strukturę dwuwymiarową: znaczenie nuty zależy od położenia względem pięciolinii, klucza, znaków chromatycznych, laseczki, belki, kropki, metrum i innych głosów.

Pełny OMR można podzielić na:

1. preprocessing i analizę layoutu;
2. lokalizację i klasyfikację symboli;
3. rekonstrukcję relacji oraz semantyki muzycznej.

Faster R-CNN realizuje przede wszystkim etap drugi. Score IR i reguły interpretacji realizują etap trzeci.

## 7.2. DeepScoresV2

Najważniejsze cechy:

- duży syntetyczny zbiór drukowanych partytur;
- 136 klas symboli;
- wariant dense oraz complete;
- duża liczba bardzo małych obiektów;
- nierównowaga klas;
- axis-aligned oraz oriented bounding boxes;
- adnotacje przydatne do późniejszej interpretacji.

**Zalety:** skala, wiele klas, automatyczne i precyzyjne adnotacje, geometria zorientowana.

**Wady:** syntetyczna domena, czyste obrazy, ograniczona reprezentatywność dla zdjęć, skanów, różnych wydawnictw i rzeczywistych partytur wokalnych.

### Pytanie: Dlaczego wybrano DeepScoresV2?

**Odpowiedź wzorcowa:** Jest jednym z największych zbiorów do detekcji drukowanych symboli muzycznych, zawiera 136 klas oraz informacje o ramkach zorientowanych. Dobrze odpowiada zadaniu detekcji obiektowej, choć wymaga augmentacji i testów domenowych.

## 7.3. Faster R-CNN

Faster R-CNN jest detektorem dwustopniowym.

### 7.3.1. Region Proposal Network

RPN analizuje mapę cech i dla zestawu anchors przewiduje:

- prawdopodobieństwo obecności obiektu;
- poprawkę położenia i rozmiaru kotwicy.

Po filtrowaniu i NMS pozostają proposals.

### 7.3.2. Drugi etap

RoIAlign pobiera dla każdego proposal mapę cech o stałym rozmiarze. Następnie główca:

- klasyfikuje obiekt;
- doprecyzowuje bounding box.

### Pytanie: Dlaczego detektor dwustopniowy?

**Odpowiedź wzorcowa:** Zapewnia dobrą jakość lokalizacji i oddziela generowanie regionów od dokładnej klasyfikacji. Jest odpowiedni dla gęstych, małych symboli, choć jest wolniejszy i kosztowniejszy od detektorów one-stage.

## 7.4. Własny backbone

Backbone `scratch_cnn`:

- jest trenowany od zera;
- używa konwolucji  $3 \times 3$ ;
- korzysta z GroupNorm i SiLU;
- w finalnej linii ma kanały [96, 192, 384, 512];
- zwraca jedną mapę cech;
- pozwala ustawić output stride 8 albo 16.

**Pytanie: Dlaczego GroupNorm zamiast BatchNorm?**

**Odpowiedź wzorcowa:** Trening używa batch size 1. BatchNorm miałby bardzo niestabilne statystyki batcha. GroupNorm normalizuje grupy kanałów wewnątrz próbki i nie zależy od liczby obrazów w batchu.

**Pytanie: Dlaczego trenowanie od zera mogło mieć sens?**

**Odpowiedź wzorcowa:** Partytury są geometrycznymi, prawie binarnymi dokumentami odmiennymi od ImageNet. Własny backbone dawał pełną kontrolę nad stride'em i małymi obiektami.

**Pytanie: Jaka jest wada braku pretreningu?**

**Odpowiedź wzorcowa:** Model nie korzysta z wcześniej nauczonych filtrów, potrzebuje więcej danych i czasu, a przy ograniczonym zbiorze może generalizować gorzej. Sensownym baseline'em byłby pretrenowany ResNet z FPN.

## 7.5. Anchors i mikro-kotwice

Zastosowano rozmiary:

[2, 4, 8, 16, 32, 64]

oraz proporcje:

[0,1, 0,2, 0,5, 1, 2, 5, 10].

Tak szeroki zakres odpowiada kropkom, główkom nut, pionowym laseczkom, poziomym belkom, łukom i innym wydłużonym symbolom.

**Pytanie: Co się stanie, gdy anchors są źle dobrane?**

**Odpowiedź wzorcowa:** Ich IoU z ground truth będzie niskie, RPN otrzyma mniej dobrych pozytywnych przykładów, a małe lub ekstremalnie wydłużone obiekty mogą nie generować dobrych proposals.

## 7.6. Stride 8 i 16

Output stride określa, ile pikselom obrazu odpowiada przesunięcie o jedną pozycję mapy cech.

**Stride 8:**

- wyższa rozdzielczość mapy;

- lepsza szansa zachowania małych symboli;
- większy koszt pamięci i obliczeń;
- więcej pozycji, szumu i kandydatów.

### Stride 16:

- mniejsza mapa i koszt;
- większy efektywny kontekst;
- większe ryzyko utraty małych szczegółów.

#### 7.6.1. Wyniki stride'u

Na Teście bazowym z augmentacją:

- stride 16: mAP 0,767, F1 0,877;
- stride 8: mAP 0,793, F1 0,897;
- AP50 spadło z 0,943 do 0,921;
- AP75 wzrosło z 0,858 do 0,875.

Na Teście degradowanym:

- mAP: 0,685 vs 0,688;
- precision: 0,718 vs 0,820;
- recall: 0,881 vs 0,766.

**Do zapamiętania:** Stride 8 nie był lepszy we wszystkim. Poprawił zagregowany wynik i dokładniejszą lokalizację na danych bazowych, ale na degradowanych głównie zmienił kompromis między precision i recall.

#### Pytanie: Jak może jednocześnie wzrosnąć precision i spaść recall?

**Odpowiedź wzorcowa:** Model generuje mniej fałszywych predykcji, ale pomija więcej prawdziwych obiektów. Może to wynikać ze zmiany rozkładu confidence i jakości proposal, a nie tylko z samej zdolności widzenia szczegółów.

#### 7.7. Kafelkowanie stron

Pełna strona jest zbyt duża, aby jednocześnie zachować drobne symbole i rozsądny koszt. Zmniejszenie całej strony zniszczyłoby szczegóły. Dlatego:

1. strona jest dzielona na nachodzące kafle;
2. każdy kafelek jest analizowany niezależnie;
3. predykcje są przesuwane do współrzędnych strony;
4. per-class NMS usuwa duplikaty.

## 7.8. Overlap

Overlap zwiększa szansę, że symbol przecięty granicą jednego kafła będzie w całości widoczny w drugim. Zbyt duży overlap:

- zwiększa liczbę kafli i koszt;
- tworzy więcej duplikatów;
- nie gwarantuje poprawy, jeżeli NMS lub kontekst są niewłaściwe.

## 7.9. Wyniki geometrii kafli

Porównano rozmiary 768, 1024 i 1280 oraz overlap 128, 256 i 384.

- najwyższy mAP bazowy: 0,805, konfiguracja 768/256;
- najwyższy mAP degradowany: około 0,721, 768/128 lub 768/256;
- zwiększanie overlapu nie dawało monotonicznej poprawy;
- rodzina 1280 była ogólnie słabsza;
- wpływ rozmiaru kafła był silniejszy niż samego overlapu.

### Pytanie: Dlaczego mniejszy kafel może pomóc?

**Odpowiedź wzorcowa:** Po przeskalowaniu do wejścia sieci symbol zajmuje względnie więcej pikseli, więc drobne detale są łatwiejsze do rozpoznania. Ceną jest mniejszy kontekst.

### Pytanie: Dlaczego duży kafel nie zawsze pomaga długim obiektom?

**Odpowiedź wzorcowa:** Większy kontekst zmniejsza względny rozmiar lokalnych cech. Dla beam, tie i slur rozdzielczość detalu mogła być ważniejsza niż pełna długość symbolu. Staff było wyjątkiem i korzystało z szerokiego kontekstu.

## 7.10. NMS

Non-Maximum Suppression:

1. sortuje detekcje według confidence;
2. zachowuje najlepszą;
3. usuwa ramki tej samej klasy o IoU przekraczającym próg;
4. powtarza procedurę.

**Pułapka:** Zbyt niski próg NMS może usunąć dwa prawdziwe, blisko położone symbole. Zbyt wysoki pozostawi duplikaty z sąsiednich kafli.

## 7.11. Oriented bounding boxes

Axis-aligned box dla ukośnego lub cienkiego symbolu obejmuje dużo tła. Dodatkowa głowica oriented:

- korzysta z cech RoI;

- przewiduje osiem znormalizowanych współrzędnych czterech punktów;
- używa sigmoid;
- jest uczona Smooth L1 Loss;
- po inferencji przelicza punkty na współrzędne obrazu.

**Pytanie: Czy jest to pełny rotated Faster R-CNN?**

**Odpowiedź wzorcowa:** Nie. Podstawowy detector nadal generuje axis-aligned proposals i boxy. Wielokąt zorientowany jest dodatkową regresją dla wykrytego regionu.

## 7.12. Metryki detekcyjne

IoU:

$$\text{IoU} = \frac{|B_{\text{pred}} \cap B_{\text{ref}}|}{|B_{\text{pred}} \cup B_{\text{ref}}|}.$$

AP to pole pod krzywą precision–recall dla klasy i progu IoU:

$$AP_{c,t} = \int_0^1 p_{c,t}(r) dr.$$

W pracy:

- AP50 oznacza próg IoU 0,50;
- AP75 oznacza próg 0,75;
- mAP jest średnią po klasach i progach 0,50–0,95 co 0,05.

**Pytanie: Dlaczego IoU jest problematyczne dla małych obiektów?**

**Odpowiedź wzorcowa:** Przesunięcie ramki o kilka pikseli może stanowić dużą część jej rozmiaru i gwałtownie obniżyć IoU, mimo że lokalizacja nadal jest użyteczna dla interpretacji.

**Pytanie: Co oznacza wysokie AP50 i niższe AP75?**

**Odpowiedź wzorcowa:** Model zazwyczaj znajduje obiekt, ale jego ramka nie jest wystarczająco dokładna przy bardziej rygorystycznym wymaganiu lokalizacji.

**Pytanie: Dlaczego mean IoU i oriented L1 nie wystarczą?**

**Odpowiedź wzorcowa:** Są liczone tylko dla dopasowanych predykcji. Model może mieć dobre ramki dla niewielkiej liczby wykrytych obiektów, a jednocześnie niski recall.

## 7.13. Augmentacje

**Podstawowe:**

- rotacja;
- app-scale jitter;
- jasność, kontrast i gamma;

- szum Gaussa i Gaussian blur;
- kompresja JPEG;
- downscaling;
- symulacja rozlewania i ścięć atramentu.

#### Heavy dodatkowo:

- perspektywa;
- nierównomierne oświetlenie;
- motion blur;
- salt-and-pepper noise.

Transformacje geometryczne muszą przekształcać zarówno axis-aligned, jak i oriented boxes. Obiekty zbyt mocno obcięte lub zbyt małe po transformacji są usuwane.

#### 7.13.1. Wyniki augmentacji

Spadek mAP pomiędzy Testem bazowym i degradowanym:

| Reżim                  | Spadek mAP |
|------------------------|------------|
| Bez augmentacji        | 0,272      |
| Augmentacje podstawowe | 0,105      |
| Photo-scan heavy       | 0,081      |

#### Pytanie: Czy augmentacje dowodzą odporności na zdjęcia?

**Odpowiedź wzorcowa:** Nie. Dowodzą odporności na zdefiniowany rozkład syntetycznych degradacji. Prawdziwe zdjęcia mogą zawierać inne kombinacje cieni, perspektywy, zagięć, ostrości, papieru i fontów.

#### 7.14. Najtrudniejsze klasy

Niskie AP50 miały m.in.:

- tuplet9 – skrajnie rzadkie;
- staff – częste, lecz wrażliwe na przecięcie i geometrię;
- noteheadDoubleWholeInSpace;
- ottavaBracket;
- stem;
- ledgerLine.

#### Pytanie: Dlaczego support nie wyjaśnia całego wyniku?

**Odpowiedź wzorcowa:** Rzadkie klasy mają mało danych, lecz częste klasy także mogą być trudne ze względu na geometrię, podobieństwo do innych symboli, zależność od kontekstu lub przecięcie granicą kafla. Przykładem są stem i ledgerLine.



**Pytanie: Dlaczego stem może być mylony z barline?**

**Odpowiedź wzorcowa:** Oba są cienkimi, pionowymi strukturami. Rozróżnienie wymaga kontekstu: stem łączy się z notehead i beam/flag, a barline przecina wysokość jednej lub kilku pięciolinii.

## 7.15. Ograniczenia metodologiczne OMR

### 7.15.1. Pojedynczy seed

Nie wiadomo, czy małe różnice nie wynikają z inicjalizacji, kolejności danych i losowych augmentacji. Lepszy protokół obejmowałby 3–5 seedów, średnią, odchylenie standardowe i przedziały ufności.

### 7.15.2. Wybór checkpointu na teście

`deepscores_test.json` służył jako źródło `val_map`, do early stopping, wyboru checkpointu i raportowania. Powoduje to optymistyczne obciążenie wyniku.

**Pytanie: Jak powinien wyglądać poprawiony podział?**

**Odpowiedź wzorcowa:** Train do uczenia, osobny validation do wyboru checkpointu i hiperparametrów oraz nietykany test użyty dopiero do końcowej oceny.

### 7.15.3. Różny budżet kroków

Mniejsze kafle generowały więcej próbek. Przy tej samej liczbie epok oznaczało to różną liczbę aktualizacji optymalizatora.

**Pytanie: Jak uczciwiej porównać rozmiary kafli?**

**Odpowiedź wzorcowa:** Utrzymać stałą liczbę optimizer steps, liczbę obejrzanych obiektów lub równoważny koszt obliczeniowy, a następnie wykonać wiele seedów.

## 7.16. Alternatywy OMR

**RetinaNet** One-stage i focal loss dla niezbalansowanych klas.

**FCOS** Anchor-free detector.

**YOLO** Szybka inferencja i proste wdrożenie.

**DETR/Deformable DETR** Set prediction i globalny kontekst; Deformable DETR lepiej radzi sobie z małymi obiektami niż klasyczny DETR.

**Rotated Faster R-CNN** Natywne rotated proposals i boxy.

**Mask R-CNN** Maski symboli.

**Segmentacja** Pikselowa klasyfikacja symboli, lecz trudne rozdzielenie instancji.

**GNN** Rekonstrukcja relacji pomiędzy wykrytymi symbolami.

**Image-to-sequence** Bezpośrednia generacja MusicXML lub innej notacji.

## 7.17. Bank pytań: OMR

### Pytanie: Dlaczego val loss nie odpowiadał rankingowi mAP?

**Odpowiedź wzorcowa:** Strata treningowa jest sumą lokalnych strat RPN, klasyfikacji i regresji, a mAP zależy od rankingów confidence, NMS, progów IoU i wyników wszystkich klas. Niższa strata nie musi oznaczać lepszej metryki końcowej.

### Pytanie: Dlaczego próg confidence wynosił tylko 0,05?

**Odpowiedź wzorcowa:** W gęstej detekcji małych symboli niski próg zwiększa recall i pozwala krzywej precision–recall ocenić szeroki zakres confidence. Późniejsze filtrowanie i NMS usuwają część słabych predykcji.

### Pytanie: Czy najwyższy mAP gwarantuje najlepszy Score IR?

**Odpowiedź wzorcowa:** Nie. mAP waży klasy i progi detekcyjne, ale błędy nie mają równego znaczenia muzycznego. Pominięty notehead, clef lub accidental może być ważniejszy niż błąd symbolu niewykorzystwanego przez obecny SVS.

### Pytanie: Jak zbudować metrykę OMR zorientowaną na wynik muzyczny?

**Odpowiedź wzorcowa:** Można mierzyć pitch error, duration error, note precision/recall, poprawność taktów, edit distance sekwencji nut, zgodność MusicXML albo wpływ na MIDI i SVS.

### Pytanie: Co byłoby ważniejsze w kolejnym badaniu: wyższy mAP czy mniej błędów melodii?

**Odpowiedź wzorcowa:** Dla celu systemu ważniejsza jest semantyczna poprawność melodii i rytmu. mAP pozostaje niezbędną metryką detektora, ale warto zoptymalizować klasy i błędy według ich wpływu na kolejne etapy.

## 8. Igor Staręga: Score IR i interpretacja muzyczna

### 8.1. Rola Score IR

Score IR zawiera:

- znormalizowane symbole OMR;
- pięciolinie i systemy;
- klucze i znaki przykluczowe;
- nuty, pauzy, relacje, metrum i tempo;
- tekst i przypisania tekst–nuta;
- confidence, źródła, warningi i naprawy;
- dane do MusicXML, MIDI, odsłuchu pianina i SVS.

W przeciwieństwie do CSV, Score IR zachowuje informacje, których obecny SVS jeszcze nie wykorzystuje: dynamikę, artykulację, fermaty, ornamenty, łuki i strukturę systemów.

### 8.2. Rekonstrukcja wysokości

Wysokość zależy od:

- pozycji notehead względem linii i pól;
- odstępu między liniami;
- klucza;
- linii dodanych;
- znaku chromatycznego;
- znaku przykluczowego.

Konwersja MIDI do częstotliwości:

$$f = 440 \cdot 2^{\frac{m-69}{12}}.$$

**Pytanie: Dlaczego sama współrzędna  $y$  nie wystarcza do wysokości?**

**Odpowiedź wzorcowa:** Ta sama pozycja graficzna oznacza inną wysokość w różnych kluczach. Potrzebna jest także geometria pięciolinii, informacja o liniach dodanych i znakach chromatycznych.

### 8.3. Rekonstrukcja rytmu

Czas trwania jest wnioskowany z:

- typu notehead;
- stem;
- flag;
- liczby poziomów beam;
- augmentation dot;
- typu rest;
- sumy czasu w takcie i metrum.

### 8.4. Metrum i naprawa taktów

Metrum może pochodzić z:

- symboli time signature;
- parametrów użytkownika;
- wnioskowania z długości taktów;
- fallbacku.

Jeżeli takt ma za mało czasu, system może dodać synthetic rest. Naprawa jest jawnie zapisana. Jeżeli takt ma za dużo czasu, system powinien ostrzegać zamiast dowolnie usuwać nuty.

**Pytanie: Czy synthetic rest jest fałszowaniem wyniku?**

**Odpowiedź wzorcowa:** Nie, jeżeli jest jawnie oznaczony jako naprawa i służy zachowaniu osi czasu. Nie może być przedstawiany jako symbol wykryty na obrazie. Użytkownik powinien móc odróżnić percepcję od rekonstrukcji.

## 8.5. Tie, slur i melisma

**Tie** Łączy nuty o tej samej wysokości i wydłuża jedno zdarzenie dźwiękowe.

**Slur** Oznacza frazowanie/legato i nie musi łączyć tej samej wysokości.

**Melisma** Jedna sylaba jest śpiewana na kilku nutach.

Mylenie tie i slur może zmienić czas fonemu albo sposób artykulacji.

## 8.6. Dopasowanie tekstu do nut

System wykorzystuje:

- przypisanie regionu tekstu do pięciolinii;
- kolejność geometryczną;
- podział tekstu na tokeny i sylaby;
- myślniki;
- dynamic programming dla dopasowania token–nuta;
- relacje tie/slur i melismę;
- confidence OCR i quality gates;
- CMUdict oraz opcjonalnie MFA/G2P.

### Pytanie: Dlaczego potrzebny jest dynamic programming?

**Odpowiedź wzorcowa:** Proste dopasowanie jeden-do-jednego zawodzi przy pauzach, melismach, brakujących tokenach i nierównych odstępach. DP może minimalizować globalny koszt przypisać, pominąć i kontynuacji.

## 8.7. Alternatywy interpretacji

- graf symboli i Graph Neural Network;
- constraint solving z zasadami muzyki;
- probabilistyczny model relacji;
- model sekwencyjny generujący MusicXML;
- interaktywna korekta człowieka;
- wspólne uczenie detekcji i relacji;
- przekazywanie pełnych rozkładów niepewności zamiast pojedynczych decyzji.

# 9. Igor Starega: Singing Voice Synthesis

## 9.1. SVS a TTS

TTS przewiduje mowę z tekstu. SVS musi dodatkowo kontrolować:

- wysokość melodii;
- rytm i długość nut;
- długości fonemów;
- dźwięczność i pauzy;
- vibrato i mikroprozodię;
- styl, głos, dynamikę i frazowanie.

#### **Pytanie: Dlaczego sam tekst nie wystarcza?**

**Odpowiedź wzorcowa:** Tekst nie określa, kiedy fonem ma się rozpocząć, jak długo trwać ani z jaką wysokością zabrzmieć. Te informacje pochodzą z partytury i Score IR.

### **9.2. Dane GTSinger**

Przygotowany podzbiór:

- 4602 próbki treningowe;
- 225 walidacyjnych;
- jeden język;
- trzy głosy angielskie;
- pięć stylów;
- słownik 68 tokenów wraz z tokenami specjalnymi.

Golden set zawiera dziesięć ręcznie kontrolowanych utworów i nie służy do treningu.

#### **Pytanie: Dlaczego użyto oracle golden setu?**

**Odpowiedź wzorcowa:** Oracle pomija błędy OCR, OMR i dopasowania tekstu, dzięki czemu można ocenić sam tor SVS. Bez oracle nie wiadomo, czy zły wokal wynika z syntezy, czy z błędnych nut i fonemów.

### **9.3. Fonemy i G2P**

Fonemy zamiast słów:

- umożliwiają generowanie słów niewidzianych w treningu;
- lepiej odpowiadają artykulacji;
- pozwalają rozdzielać czas między samogłoski i spółgłoski;
- ograniczają zależność od zamkniętego słownika słów.

G2P zamienia grafemę na fonemy. System korzysta z reprezentacji zbliżonej do ARPAbet.

### **9.4. Alokacja czasu fonemów**

Samogłoski zwykle niosą długą, dźwięczną część śpiewu. Spółgłoski są krótsze i odpowiadają atakowi lub zakończeniu sylaby. W repozytorium allocator może przyznać samogłosce większą wagę niż spółgłosce, zachowując sumę czasu zdarzenia.

**Pytanie: Dlaczego równy podział czasu może brzmieć mechanicznie?**

**Odpowiedź wzorcowa:** Przeznacza zbyt dużo czasu na zwarte lub szczelinowe spółgłoski, a za mało na samogłoskę. W naturalnym śpiewie to samogłoska jest zwykle podtrzymywana na wysokości nuty.

**9.5. Reprezentacja audio****9.5.1. Próbkowanie**

Częstotliwość próbkowania 22050 Hz oznacza 22050 próbek na sekundę. Częstotliwość Nyquista:

$$f_N = \frac{22050}{2} = 11025 \text{ Hz.}$$

**9.5.2. STFT**

STFT dzieli sygnał na zachodzące okna i oblicza transformatę Fouriera dla każdego okna. Parametry:

- FFT 1024;
- długość okna 1024;
- hop 256;
- 80 pasm mel;
- zakres 40–11025 Hz.

Krok czasowy:

$$\frac{256}{22050} \approx 0,0116 \text{ s,}$$

czyli około 86 ramek na sekundę.

**9.5.3. Mel-spektrogram**

Mel-spektrogram jest mapą czasu, pasm częstotliwości i energii. Skala mel przybliża nieliniową percepcję częstotliwości człowieka. Jest krótsza i łatwiejsza do modelowania niż waveform, ale nie zachowuje pełnej informacji fazowej.

**Pytanie: Dlaczego potrzebny jest wokoder?**

**Odpowiedź wzorcowa:** Mel-spektrogram nie jest gotową falą audio i nie przechowuje kompletnej fazy. Wokoder uczy się rekonstruować realistyczny waveform zgodny z mel,  $F_0$  i energią.

**9.6.  $F_0$ , MIDI i centy**

$F_0$  to częstotliwość podstawowa sygnału dźwięcznego. Błąd w centach:

$$e_{F_0} = 1200 \log_2 \left( \frac{\widehat{F_0}}{F_0} \right).$$

- 100 centów = półton;

- 1200 centów = oktawa;
- błąd liczy się na ramkach dźwięcznych.

**Pytanie: Dlaczego centy zamiast herców?**

**Odpowiedź wzorcowa:** Percepcja interwałów jest logarytmiczna. Różnica 10 Hz ma inne znaczenie przy 100 Hz i 1000 Hz, natomiast cent opisuje względny interwał muzyczny.

**9.7. Architektura modelu akustycznego**

Finalny model obejmuje:

1. embeddings fonemów;
2. embeddings języka, głosu i stylu;
3. cechy wysokości, czasu, tempa, tonacji, voiced i slur;
4. Transformer event encoder;
5. duration predictor;
6. length regulator;
7. frame-level Conformer;
8. predykcję odchylenia  $F_0$  i energii;
9. prosody feedback;
10. mel projection;
11. postnet;
12. detail projection;
13. residualny mel refiner.

**9.8. Transformer event encoder**

Self-attention pozwala zdarzeniu korzystać z kontekstu innych fonemów i nut. Kodowanie pozycyjne jest konieczne, ponieważ attention samo w sobie nie zna kolejności.

**Pytanie: Po co szeroki kontekst w śpiewie?**

**Odpowiedź wzorcowa:** Sposób wykonania sylaby zależy od frazy, kierunku melodii, sąsiednich dźwięków, granic słów, powtórzeń oraz miejsca oddechu, a nie tylko od pojedynczej nuty.

**9.9. Length regulator**

Reprezentacja zdarzenia jest powtarzana tyle razy, ile ramek akustycznych wynika z czasu trwania. Pozwala to:

- jawnie kontrolować rytm;
- generować ramki równoległe;
- uniknąć autoregresyjnego attention alignment;
- zachować synchronizację z partyturą.

## 9.10. Conformer

Blok Conformer zawiera:

- połowę modułu feed-forward;
- multi-head self-attention;
- moduł konwolucyjny z GLU i depthwise convolution;
- drugą połowę feed-forward;
- residual connections i normalizację.

**Pytanie: Czym Conformer różni się od Transformera?**

**Odpowiedź wzorcowa:** Dodaje silny moduł konwolucyjny modelujący lokalne wzorce, zachowując attention dla zależności globalnych. Jest to korzystne w audio, gdzie lokalna ciągłość ma duże znaczenie.

## 9.11. Score-relative $F_0$

Model przewiduje odchylenie względem wysokości wynikającej z partytury, zamiast pełnego  $F_0$  od zera:

$$\widehat{F_0} = F_{0,\text{score}} \cdot 2^{\Delta c/1200}.$$

W v11 odchylenie ograniczono do około 120 centów.

**Pytanie: Dlaczego to podejście jest korzystne?**

**Odpowiedź wzorcowa:** Partytura zawiera silną informację o pożądanej melodii. Model może skupić się na mikroprozodii, vibrato i przejściach, a ograniczenie odchylenia zmniejsza ryzyko utraty kontroli wysokości.

## 9.12. Prosody feedback i teacher forcing

Model najpierw przewiduje  $F_0$  i residual energii, a następnie podaje je z powrotem do dekodera mel.

Teacher forcing czasami zastępuje przewidywane wartości referencją podczas treningu.

**Pytanie: Jaka jest wada teacher forcingu?**

**Odpowiedź wzorcowa:** Jeżeli jest stosowany zbyt często, model przyzwyczaja się do idealnych danych, których nie ma w inferencji. Powstaje exposure bias. Dlatego użyto niewielkiego udziału teacher forcingu.

## 9.13. Postnet, detail projection i mel refiner

**Postnet** Konwolucyjna poprawka do bazowego mel-spektrogramu.

**Detail projection** Dodatkowy residual przewidujący lokalny detal.

**Mel refiner** Kilkuwarstwowa, dylatowana sieć residualna korygująca wynik po postnetcie.

Wyjście refinera jest inicjalizowane zerami, więc początkowo nie zaburza istniejącego modelu.



## 9.14. Straty modelu akustycznego

Poza podstawowym L1/MSE mel zastosowano składniki:

- pierwszej różnicy czasowej;
- drugiej różnicy/acceleration;
- wariancji;
- wysokich pasm;
- subbandów;
- mel detail;
- $F_0$ ;
- gładkości  $F_0$ ;
- energii;
- duration.

**Pytanie: Dlaczego mel L1 nie wystarcza?**

**Odpowiedź wzorcowa:** Średni błąd promuje wygładzanie. Model może mieć niski L1, ale utracić ostre przejścia, wysokie pasma i lokalne struktury odpowiedzialne za wyrazistość oraz naturalność.

## 9.15. Wokoder inspirowany HiFi-GAN

Generator:

- łączy mel z projekcjami pitch i energy;
- zwiększa rozdzielczość czasową transposed convolutions;
- używa residual blocks;
- opcjonalnie dodaje źródło harmoniczne zależne od  $F_0$ .

Dyskryminatory:

**Multi-Period Discriminator** Analizuje periodyczność przy różnych okresach.

**Multi-Scale Discriminator** Analizuje waveform przy kilku skalach czasowych.

**Mel Sub-Band Discriminator** Oddzielnie ocenia zakresy mel, zwiększając uwagę na szczegóły pasm.

## 9.16. GAN i feature matching

Generator próbuje stworzyć audio uznane przez dyskryminator za prawdziwe. Dyskryminator uczy się odróżniać sygnał prawdziwy od wygenerowanego.

Feature matching porównuje aktywacje pośrednich warstw dyskryminatora:

$$\mathcal{L}_{FM} = \sum_l \|D_l(x) - D_l(\hat{x})\|_1.$$

**Pytanie: Po co feature matching?**

**Odpowiedź wzorcowa:** Stabilizuje trening GAN i daje generatorowi bogatszy sygnał niż sama końcowa decyzja dyskryminatora. Promuje zgodność struktury na wielu poziomach.

**9.17. Source-filter**

Source-filter jest inspirowany fizycznym modelem głosu:

- source – okresowe pobudzenie krtaniowe zależne od  $F_0$ ;
- filter – kształtowanie barwy przez trakt głosowy.

W finalnej konfiguracji zastosowano 10 harmoniczných, maskę voiced i dodawanie źródła na kolejnych skalach generatora.

**Pytanie: Dlaczego samo przekazanie  $F_0$  jako dodatkowego kanału może nie wystarczyć?**

**Odpowiedź wzorcowa:** Generator może nauczyć się ignorować warunek, jeżeli mel i inne cechy wystarczają do minimalizacji strat. Jawne źródło harmoniczných silniej wiąże strukturę okresową audio z  $F_0$ .

**9.18. Pitch-shift sensitivity**

Podczas treningu celowo przesuwają się warunek  $F_0$ . Wokoder powinien odpowiednio zmienić wynik. Strata karze sytuację, w której przesunięcie pitch prawie nie wpływa na mel/audio.

**9.19. Niedopasowanie model akustyczny-wokoder**

Wokoder trenowany tylko na prawdziwych melach podczas inferencji dostaje mele przewidywane, które są gładziej i zawierają inne błędy. Jest to domain mismatch na interfejsie modeli.

Finalny wokoder dostrojono na mel-spektrogramach przewidywanych przez model akustyczny.

**Pytanie: Dlaczego jest to ważne?**

**Odpowiedź wzorcowa:** Wokoder uczy się rozkładu wejścia, który rzeczywiście otrzyma podczas inferencji. Zmniejsza to różnicę między idealnym mel treningowym a niedoskonałym mel generowanym.

**9.20. Audio-proxy**

Procedura:

1. model akustyczny przewiduje mel;
2. wokoder generuje waveform;
3. z waveformu ponownie wyznaczany jest mel;
4. mel audio jest porównywany z referencją.

**Pytanie: Co mierzy audio-proxy?**

**Odpowiedź wzorcowa:** Łączny błąd modelu akustycznego i wokodera. Jest bliższymi końcowemu zastosowaniu niż L1 bezpośredniego mel, ale nadal nie zastępuje oceny percepcyjnej.

### 9.21. Wyniki finalnego SVS

| Wariant / źródło $F_0$ | MAE $F_0$ [c] | P95 [c] | > 100 c [%] |
|------------------------|---------------|---------|-------------|
| Clean, score           | <b>8,87</b>   | 40,38   | 2,59        |
| Humanized              | 9,69          | 40,85   | 2,65        |
| Blend                  | 15,35         | 45,40   | 2,59        |
| Predicted              | 22,76         | 60,48   | 2,68        |

Najtrudniejsza próbka: *Near the Cross*, clean MAE 13,64 centa, P95 123,01 centa.

**Pytanie: Dlaczego wynik 8,87 centa nie dowodzi naturalności?**

**Odpowiedź wzorcowa:** Mierzy zgodność wysokości wykrytej w waveformie z melodią score. Nie mierzy bezpośrednio barwy, zrozumiałości, artykulacji, emocji, podobieństwa głosu ani płynności frazy.

**Pytanie: Czy użycie score  $F_0$  czyni wynik trywialnym?**

**Odpowiedź wzorcowa:** Nie całkowicie. Mierzone jest  $F_0$  rzeczywiście obecne w wygenerowanym waveformie, więc test sprawdza, czy model akustyczny i wokoder realizują warunek. Nie jest to jednak test samodzielnego przewidywania melodii przez model.

### 9.22. Clean i humanized

Humanized dodaje przed wokoderem:

- vibrato o głębokości 8 centów;
- vibrato dla nut trwających co najmniej 0,70 s;
- początkowe podciągnięcie 8 centów;
- powolny drift 1,5 centa.

**Pytanie: Dlaczego humanized ma wyższy MAE?**

**Odpowiedź wzorcowa:** Naturalizacja celowo odchyła  $F_0$  od idealnej linii score. MAE rośnie, ale ważne jest, czy ogon błędów i odsetek przekroczeń półtonu pozostają bezpieczne oraz czy odsłuch się poprawia.

### 9.23. Transpozycja

W golden secie użyto transpozycji o  $-12$  półtonów dla EN-Tenor-1, aby dopasować melodie do zakresu treningowego głosu.

**Pytanie: Czy transpozycja jest rozwiązaniem generalizacji?**

**Odpowiedź wzorcowa:** Nie. Jest kontrolą eksperymentalną. Docelowo system powinien dobierać głos, ostrzegać o zakresie, stosować pitch augmentation albo trenować na szerszym zakresie.

### 9.24. Ograniczenia ewaluacji SVS

- tylko dziesięć próbek;
- brak szerokiego MOS/CMOS;
- brak formalnej grupy słuchaczy;

- brak niezależnej oceny naturalności, intelligibility i singer similarity;
- pYIN może popełniać błędy oktawowo;
- metryka zależy od voiced/unvoiced detection;
- oracle pomija błędy pełnego pipeline'u;
- próbki transponowano;
- brak porównania z zewnętrznym systemem SVS.

### 9.25. Jak zaprojektować test percepcyjny

Możliwe badanie:

1. zebrać co najmniej kilkadziesiąt próbek i kilku systemów/baseline'ów;
2. zrandomizować kolejność;
3. nie ujawniać wariantu;
4. zebrać niezależne oceny naturalności, zrozumiałości, zgodności melodii i barwy;
5. użyć MOS 1–5 lub porównań parowych CMOS;
6. raportować liczbę słuchaczy, doświadczenie muzyczne, średnią i przedział ufności;
7. analizować zgodność oceniających.

### 9.26. Alternatywy SVS

**DiffSinger** Dyfuzyjna generacja mel, dobra jakość kosztem większej liczby kroków.

**FastSpeech 2** Nieautoregresyjny model z variance adaptor.

**Tacotron 2** Autoregresyjny acoustic model, lecz alignment może być niestabilny.

**WORLD** Interpretowalny klasyczny wokoder i dobry baseline, ale zwykle mniej naturalny.

**NSF-HiFiGAN/SiFi-GAN** Silniejsze jawne modelowanie źródła i pitch.

**VITS** Bardziej zintegrowany model probabilistyczny, trudniejszy do jawnej kontroli.

**Flow matching/diffusion vocoder** Potencjalnie wysoka jakość kosztem złożoności.

## 10. Najważniejsze ograniczenia całej pracy

1. **Domain shift lokalizacji i OCR.** Dane dokumentowe nie odpowiadają bezpośrednio partyturom wokalnym.
2. **Syntetyczna domena OMR.** DeepScoresV2 nie jest zbiorem zdjęć użytkowników.
3. **Jeden seed.** Brak oszacowania wariancji wyników.
4. **Brak niezależnego validation/test OMR.** Checkpoint wybierano na `deepscores_test.json`.
5. **Nierówny budżet treningowy kaffi.** Ta sama liczba epok dawała inną liczbę optimizer steps.
6. **Mały golden set SVS.** Dziesięć utworów nie opisuje pełnego rozkładu muzyki.

7. **Brak pełnej ewaluacji słuchowej.**
8. **Oracle SVS.** Wynik nie jest wynikiem pełnego pipeline'u.
9. **Transpozycja.** Część melodii dostosowano do zakresu wybranego głosu.
10. **Heurystyki Score IR.** Mogą zawodzić przy polifonii, nietypowym layoucie i złożonej notacji.

**Pytanie: Które ograniczenie jest najpoważniejsze?**

**Odpowiedź wzorcowa:** Zależy od pytania badawczego. Dla wiarygodności porównań OMR najważniejszy jest brak niezależnego validation/test i wielu seedów. Dla praktycznego systemu największym problemem jest domain shift. Dla twierdzeń o jakości SVS najważniejszy jest brak pełnego testu percepcyjnego.

## 11. Pytania wspólne i metodologiczne

**Pytanie: Jaki jest najważniejszy wkład pracy?**

**Odpowiedź wzorcowa:** Kompletna, obserwowalna infrastruktura od obrazu/PDF-u do reprezentacji muzyczno-tekstowej i audio, wraz z kontrolowanymi eksperymentami OMR oraz diagnostyką połączenia modelu akustycznego z wokoderem. Nie jest nim pojedynczy rekord jednej metryki.

**Pytanie: Czy system jest end-to-end?**

**Odpowiedź wzorcowa:** Jest end-to-end z perspektywy użytkownika, ponieważ przyjmuje obraz i generuje audio. Nie jest jednym modelem trenowanym end-to-end; jest modułowym pipeline'em.

**Pytanie: Jak propagują się błędy?**

**Odpowiedź wzorcowa:** Błąd maski zmienia crop OCR i może usunąć symbole przed OMR. Błąd OCR zmienia sylaby i fonemy. Błąd OMR zmienia wysokość lub czas nut. Błąd Score IR zmienia oś czasu. Nawet poprawny CSV może zostać zniekształcony przez model akustyczny lub wokoder.

**Pytanie: Jak odróżnić błąd percepcji od interpretacji?**

**Odpowiedź wzorcowa:** Porównać overlay OMR z obrazem, a następnie Score IR i SVG z surowymi detekcjami. Jeżeli symbol jest błędny lub go brakuje, to błąd percepcji. Jeżeli symbol jest poprawny, ale otrzymał złą wysokość, relację lub czas, to błąd interpretacji.

**Pytanie: Czym golden set różni się od test setu?**

**Odpowiedź wzorcowa:** Test set służy do bezstronnej ilościowej oceny modelu. Golden set jest małym, ręcznie kontrolowanym zestawem przypadków do regresji i diagnostyki całego systemu. Nie powinien być wielokrotnie używany do strojenia, bo przestałby być niezależnym punktem odniesienia.

**Pytanie: Co to jest data leakage?**

**Odpowiedź wzorcowa:** Przepływ informacji z validation lub testu do treningu albo wyboru modelu, który prowadzi do zbyt optymistycznej oceny. Przykładem jest wielokrotne dobieranie checkpointu i konfiguracji na podstawie wyników tego samego testu.

**Pytanie: Co oznacza uczciwy baseline?**

**Odpowiedź wzorcowa:** Model porównawczy oceniany na tych samych danych, podziałach, metrykach i możliwie podobnym budżecie treningowym. Powinien być wystarczająco silny i poprawnie dostrojony.

**Pytanie: Czy większy model zawsze jest lepszy?**

**Odpowiedź wzorcowa:** Nie. Może wymagać więcej danych, przeuczać się, być trudniejszy w optymalizacji i wolniejszy. W pracy większy OCR Transformer nie uzyskał przewagi, a bardziej złożone segmentery nie przewyższyły prostego U-Net.

**Pytanie: Jak ilościowo mierzyć obserwowalność?**

**Odpowiedź wzorcowa:** Można mierzyć czas lokalizacji źródła błędu, odsetek awarii poprawnie przypisanych do modułu, pokrycie klas błędów przez warningi, liczbę potrzebnych ręcznych inspekcji lub skuteczność naprawy po zastąpieniu jednego modułu oracle.

**Pytanie: Jak ocenić pełny system?**

**Odpowiedź wzorcowa:** Potrzebny jest zbiór pełnych stron z referencyjnym tekstem, nutami, osią czasu i audio. Należy raportować metryki modułów, zgodność Score IR/MusicXML, jakość MIDI, pitch i rhythm error oraz percepcyjną ocenę końcowego wokalu.

## 12. Najbardziej niebezpieczne pytania komisji

**Pytanie: Dlaczego raportujecie wynik na zbiorze używanym do wyboru checkpointu?**

**Odpowiedź wzorcowa:** To ograniczenie dostępnego protokołu DeepScoresV2 w przeprowadzonych eksperymentach. Wyniki należy interpretować głównie jako względne porównania konfiguracji. W kolejnym badaniu wydzielibyśmy osobny validation i nietykany test.

**Pytanie: Czy augmentacje dowodzą generalizacji na zdjęcia?**

**Odpowiedź wzorcowa:** Nie. Dowodzą odporności na zastosowane kontrolowane degradacje. Potrzebny jest osobny real-world test set.

**Pytanie: Dlaczego wynik SVS nie jest dowodem wysokiej jakości śpiewu?**

**Odpowiedź wzorcowa:** Główna metryka mierzy pitch accuracy na małym oracle golden secie. Brakuje szerokiej, zaślepionej oceny naturalności, zrozumiałości, barwy i frazowania.

**Pytanie: Czy score  $F_0$  nie „podaje odpowiedzi” modelowi?**

**Odpowiedź wzorcowa:** Podaje pożądaną melodię, ponieważ celem jest kontrolowana synteza z partytury. Eksperyment sprawdza, czy cały tor realizuje ten warunek w waveformie. Ablacja predicted  $F_0$  pokazuje, że sam model akustyczny jest mniej dokładny.

**Pytanie: Dlaczego Attention U-Net jest najlepszy, skoro różnica jest minimalna?**

**Odpowiedź wzorcowa:** W konkretnym uruchomieniu osiągnął najwyższe F1 i IoU. Różnica jest jednak niewielka i bez wielu seedów nie stanowi dowodu statystycznie istotnej przewagi.

**Pytanie: Dlaczego kafle 768 wygrały, mimo że mają mniej kontekstu?**

**Odpowiedź wzorcowa:** Zwiększają względny rozmiar symboli na wejściu. Dla większości klas zysk rozdzielczości przeważał nad utratą kontekstu. Staff było przykładem klasy korzystającej z większego kafła.

**Pytanie: Czy tytuł z „agentem AI” nie jest mylący?**

**Odpowiedź wzorcowa:** Pojęcie jest użyte w szerszym znaczeniu zespołu wyspecjalizowanych agentów zadaniowych i warstwy orkiestracji, nie w znaczeniu autonomicznego LLM. W pracy zakres tego pojęcia został jawnie zdefiniowany.

**Pytanie: Czy zakres pracy nie był zbyt szeroki?**

**Odpowiedź wzorcowa:** Był szeroki i to spowodowało nierówną głębokość modułów. Jednocześnie szerokość była niezbędna do zbadania przejścia od obrazu do audio i obserwowalności całego systemu.

## 13. Liczby, które warto znać z pamięci

### 13.1. Lokalizacja tekstu

- Attention U-Net: F1 0,909, IoU 0,832.
- U-Net: F1 0,906, IoU 0,828.
- Domyślny próg maski w aplikacji: około 0,3.
- Funkcja straty: BCEWithLogits z `pos_weight=5` + Dice.

### 13.2. OCR

- najlepszy własny: ResNet-CRNN hidden512;
- CER 0,1318;
- exact match 0,5366;
- 16842 próbki testowe;
- wejście: wysokość 32, szerokość 512;
- token blank CTC ma indeks 0.

### 13.3. OMR

- 136 klas;
- podstawowy kafel 1024, overlap 256;
- najlepsza rodzina: kafle 768;
- najlepszy bazowy mAP: 0,805;
- najlepszy degradowany mAP: około 0,721;
- stride 16  $\rightarrow$  8: mAP bazowy 0,767  $\rightarrow$  0,793;
- spadek mAP bez augmentacji: 0,272;
- spadek z augmentacją podstawową: 0,105;
- spadek heavy: 0,081;
- seed 42;
- AdamW:  $2 \cdot 10^{-4}$ , weight decay  $10^{-4}$ ;
- anchors 2–64, ratios 0,1–10;
- mAP: IoU 0,50–0,95 co 0,05.

### 13.4. SVS

- 4602 train, 225 validation;
- 3 głosy, 5 stylów, 68 tokenów;
- 22050 Hz, FFT 1024, hop 256, 80 mel bands;
- 10 próbek golden setu;
- clean score  $F_0$ : 8,87 centa MAE;
- humanized: 9,69;
- blend: 15,35;
- predicted: 22,76;
- 100 centów = półton;
- golden set transponowany o  $-12$  półtonów dla EN-Tenor-1;
- finalny model: hidden 512, 10 warstw encodera, 8 warstw Conformer;
- source-filter: 10 harmoniczych.

## 14. Szybki bank dodatkowych pytań bez pełnych odpowiedzi

### 14.1. Pytania do Michała

1. Czym różni się binaryzacja globalna od adaptacyjnej?
2. Jak działają erozja, dylatacja, opening i closing?
3. Dlaczego operacje morfologiczne są przydatne dla pięciolini?
4. Jak zachować bboxes po transformacji perspektywicznej?
5. Co to jest pole recepcyjne?
6. Jak dropout, weight decay i augmentacja ograniczają overfitting?
7. Dlaczego AdamW różni się od Adam z naiwnym L2?
8. Jak działa ReduceLROnPlateau?
9. Co robi early stopping i jakie ma ryzyko?
10. Dlaczego mixed precision przyspiesza trening?
11. Co to jest gradient clipping?
12. Jak wygląda krzywa precision–recall?
13. Dlaczego macro-mAP traktuje rzadką i częstą klasę podobnie?
14. Co to jest micro-average?
15. Jak kalibrować confidence detektora?
16. Dlaczego AP dla klas z jedną instancją jest niestabilne?
17. Jak zbadać wpływ maskowania tekstu na OMR?
18. Jak zmierzyć czas i pamięć inferencji dla różnych kafli?



19. Jak zaprojektować active learning dla trudnych klas?
20. Czy syntetyczne dane są wadą, czy zaletą?

## 14.2. Pytania do Igora

1. Jak rozróżnić pauzę od braku detekcji?
2. Jak działa znak przykluczowy i jego zasięg?
3. Czym różni się tie od slur?
4. Jak rozpoznać takt przedtaktowy?
5. Jak obsłużyć polifonię i wiele głosów?
6. Jak reprezentować akord w SVS?
7. Jak działa CMUdict?
8. Co oznaczają akcenty w ARPAbet?
9. Czym różni się voiced/unvoiced od rest?
10. Co to jest vibrato: rate i depth?
11. Co to jest formant i dlaczego wpływa na barwę?
12. Dlaczego transpozycja bez korekty formantów może zmieniać barwę?
13. Co to jest aliasing?
14. Dlaczego harmoniczne powyżej Nyquista trzeba ograniczać?
15. Co mierzy multi-resolution STFT loss?
16. Dlaczego GAN może być niestabilny?
17. Co to jest mode collapse?
18. Jak odróżnić błąd octave F0 od realnego fałszu modelu?
19. Jak mierzyć intelligibility śpiewu?
20. Jakie informacje ze Score IR nie są jeszcze wykorzystywane przez SVS?

## 15. Plan nauki przed obroną

### 15.1. Etap 1: wspólna narracja

Obaj autorzy powinni bez slajdów przećwiczyć:

1. problem i motywację – 60 sekund;
2. cały pipeline – 90 sekund;
3. tezy i najważniejsze wyniki – 2 minuty;
4. osobisty wkład – po 60 sekund;
5. trzy najważniejsze ograniczenia – 90 sekund;
6. plan dalszych prac – 60 sekund.

## 15.2. Etap 2: własny zakres

**Michał:**

- narysować z pamięci U-Net, CRNN i Faster R-CNN;
- wyprowadzić i objaśnić Precision, Recall, F1, IoU, CER, AP i mAP;
- wytłumaczyć stride, anchors, RPN, RoIAlign, NMS i tiling;
- opowiedzieć ograniczenia eksperymentów OMR bez zagłębienia do pracy.

**Igor:**

- narysować przepływ Score IR  $\rightarrow$  fonemy  $\rightarrow$  mel  $\rightarrow$  waveform;
- wyjaśnić STFT, mel,  $F_0$ , centy, length regulator, Conformer i HiFi-GAN;
- porównać score, blend i predicted  $F_0$ ;
- zaprojektować ustnie poprawny test percepcyjny.

## 15.3. Etap 3: wzajemne odpytywanie

Michał powinien zadawać Igorowi pytania krytyczne o SVS, a Igor Michałowi o OMR. Dzięki temu łatwiej wykryć skróty myślowe, które dla autora modułu wydają się oczywiste.

## 15.4. Etap 4: próbna komisja

Jedna osoba zadaje trzy pytania:

1. ogólne z pracy;
2. szczegółowe z własnego zakresu;
3. krytyczne lub alternatywne.

Odpowiedź powinna trwać 1–3 minuty. Po odpowiedzi pytający zadaje jedno dopytanie: „dlaczego?”, „jak to zmierzyć?” albo „jakie jest ograniczenie?”.

# 16. Przykładowa próbna obrona

## 16.1. Zestaw dla Michała

**Pytanie: Dlaczego w OMR wybrano Faster R-CNN, a nie YOLO?**

**Odpowiedź wzorcowa:** Priorytetem była dokładność gęstej detekcji wielu małych symboli, nie maksymalna szybkość. Dwustopniowy RPN i dokładna głowica RoI są dobrym punktem odniesienia dla DeepScoresV2. YOLO byłby wartościowym baseline’em wydajnościowym, ale wymagałby starannego dostrojenia małych obiektów i ekstremalnych proporcji.

**Pytanie: Czy wynik kafli 768 jest w pełni wiarygodny?**

**Odpowiedź wzorcowa:** Wskazuje przewagę tej rodziny w przeprowadzonym protokole, ale nie oddziela czysto wpływu geometrii od liczby kroków treningowych. Potrzebne byłyby stałe optimizer steps i wiele seedów.

**Pytanie: Jak poprawiłby Pan lokalizację tekstu?**

**Odpowiedź wzorcowa:** Zbudowałbym anotowany zbiór partytur, zastosował fine-tuning pretrenowanego encodera, ocenę end-to-end cropów i sylab oraz porównał segmentację z DBNet/CRAFT i multi-task wykrywaniem pięciolinii.

**16.2. Zestaw dla Igora****Pytanie: Dlaczego model akustyczny i wokoder są osobne?**

**Odpowiedź wzorcowa:** Rozdzielają zadanie symboliczny-input-mel od mel-waveform, pozwalają używać różnych danych, strat i metryk oraz diagnozować, czy problem powstaje przed czy po mel-spektrogramie.

**Pytanie: Dlaczego predicted  $F_0$  jest potrzebne, skoro score daje lepszy wynik?**

**Odpowiedź wzorcowa:** Predicted  $F_0$  może dostarczać naturalną mikroprozodię i odchylenia wykonawcze. Wyniki pokazują jednak, że dla ścisłej kontroli melodii powinno być ograniczane lub mieszane ze score, dopóki model nie przewiduje go stabilniej.

**Pytanie: Jak udowodniłby Pan poprawę naturalności?**

**Odpowiedź wzorcowa:** Zaślepionym testem słuchowym MOS lub porównaniami parowymi, na większym zestawie utworów, z osobnymi pytaniami o naturalność, intelligibility, pitch i barwę, wraz z przedziałami ufności i odpowiednią liczbą słuchaczy.

**17. Ostatnia checklista przed obroną**

1. Używać liczb z finalnego PDF-u: 10 próbek i 8,87 centa.
2. Umieć powiedzieć, że wynik SVS nie jest pełną oceną naturalności.
3. Nie twierdzić, że Test degradowany jest zbiorem prawdziwych zdjęć.
4. Jawnie przyznać problem wyboru checkpointu na teście.
5. Nie przedstawiać małych różnic jako statystycznie istotnych.
6. Wyjaśnić, że Score IR oddziela percepcję od interpretacji.
7. Rozróżniać pełny pipeline użytkowy od jednego modelu end-to-end.
8. Każdy autor powinien znać wkład drugiego na poziomie całego przepływu.
9. Przygotować odpowiedź, dlaczego „agent AI” nie oznacza LLM.
10. Umieć zaproponować konkretny poprawiony eksperyment, a nie tylko powiedzieć „potrzeba więcej danych”.

**18. Podsumowanie**

Najbardziej prawdopodobne pytania komisji będą dotyczyły nie kodu, lecz:

- uzasadnienia podziału na moduły;
- przejścia od geometrii strony do osi czasu;
- Score IR i obserwowalności;

- trafności metryk;
- ograniczeń protokołu OMR;
- różnicy między pitch accuracy i naturalnością SVS;
- alternatywnych architektur;
- granicy między prototypem i produktem;
- osobistego wkładu autorów.

Najlepsza odpowiedź nie polega na obronie każdej decyzji jako idealnej. Powinna pokazać, że autor rozumie mechanizm, zna kompromis, potrafi zinterpretować wynik i wie, jak zaprojektować lepszy kolejny eksperyment.